UNIVERSITÀ DEGLI STUDI DI MILANO-BICOCCA

Dipartimento di Statistica e Metodi Quantitativi

Corso di Laurea Magistrale in Biostatistica



Detection di nuclei cellulari con reti neurali convoluzionali

Relatore: Prof. Mirko Cesarini

Correlatore: Dott. Roberto Boselli

Relazione della prova finale di:

Pietro Parenti

Matricola n. 917982

Anno Accademico 2025-2026

Indice

1 Introduzione **1**

1.1 Contesto biologico e clinico 1

1.2 Il problema della detection di nuclei densi e sovrapposti 2

1.3 Obiettivi della tesi 3

1.4 Struttura del documento 5

2 Stato dell'arte **7**

2.1 Reti neurali per l'object detection ed evoluzione dei modelli YOLO 7

2.2 Generazione di dati sintetici per il training 10

3 Dati **13**

3.1 Le immagini reali (colorazione DAPI) 13

3.2 Criteri di annotazione 14

3.3 Estrazione delle zone dense (BrightAreaExtractor) 16

3.4 Analisi descrittiva delle immagini full 18

3.4.1 Distribuzione del numero di nuclei per immagine 18

3.4.2 Distribuzione delle dimensioni dei nuclei 19

3.5 Analisi descrittiva dei crop di immagini 21

3.5.1 Distribuzione delle dimensioni del crop 21

3.5.2 Distribuzione del numero di nuclei per crop 22

3.5.3 Distribuzione delle dimensioni dei nuclei 23

4 Generazione di immagini sintetiche **27**

4.1 Generatore full-image 27

4.1.1 Cluster lineari ed ellittici 28

4.1.2 Gestione dell'overlap tra nuclei 29

4.2 Generatore delle immagini zoom 29
4.2.1 Dimensioni variabili del crop 29
4.2.2 Parametri di clustering 30
4.3 Generatore di casi difficili 30
4.3.1 Motivazione: sotto-rappresentazione degli ammassi densi 30
4.3.2 Design del blob ellittico centrale 31
4.4 Validazione visiva 31

5 Architettura della pipeline **35**
5.1 Approccio generale 35
5.1.1 Motivazione dell'architettura dual-model 35
5.1.2 Panoramica del flusso: training, fine-tuning, fusione e valutazione . 36
5.2 Training del modello full 36
5.3 Training e fine-tuning del modello zoom 36
5.4 Fusione delle predizioni 38
5.4.1 Classificazione delle detection rispetto alle zone dense 38
5.4.2 Assegnazione diretta delle detection *outside_far* e *inside_far* 38
5.4.3 Non-Maximum Suppression nella cornice di confine 38
5.5 Utilizzo delle 15 immagini reali annotate 39

6 Protocollo di valutazione **41**
6.1 Limiti delle metriche COCO standard nel dominio 41
6.2 Metriche adottate 42
6.2.1 F1, Precision e Recall 43
6.2.2 mAP@50 44
6.2.3 MAE e bias di conteggio 45
6.3 Implementazione custom delle metriche 46
6.4 Ottimizzazione degli iperparametri operativi 46
6.4.1 Soglie di confidence e IoU-NMS dei singoli modelli 47
6.4.2 Margine e soglia IoU-NMS di confine per la fusione 47

7 Risultati sperimentali e discussione **49**
7.1 Modello full 49
7.2 Modello zoom 51

7.3 Pipeline dual-model 52
7.3.1 Confronto con il modello full singolo 53
7.4 Limiti del lavoro 55
7.4.1 Dimensione del dataset reale 55
7.4.2 Incertezza delle annotazioni negli ammassi densi 56
7.4.3 Calibrazione empirica del BrightAreaExtractor 56
7.4.4 Generalizzazione limitata al protocollo di acquisizione 56
7.5 Confronto con lavoro precedente 58

8 Conclusioni e sviluppi futuri **61**
8.1 Sintesi del lavoro e dei risultati 61
8.2 Implicazioni applicative e limiti residui 62
8.3 Considerazioni conclusive 63
8.4 Sviluppi futuri 64
8.4.1 Dataset reale più ampio e variabilità nell'annotazione 64
8.4.2 Zone dense e sottostima residua 64
8.4.3 Generalizzazione ad altri protocolli di acquisizione 64
8.4.4 Dal conteggio agli indici biologici 65

Elenco delle figure

2.1 Confronto prestazionale tra le diverse versioni dei modelli YOLO in termini di latenza di inferenza e accuratezza (mAP) sul dataset COCO. Fonte: Ultralytics [1]. 10

3.1 Esempio di immagine acquisita mediante microscopia a fluorescenza con colorazione DAPI. I nuclei cellulari appaiono come strutture luminose e costituiscono le immagini di partenza utilizzate in questo lavoro. 14
3.2 Esempio di immagine reale con le bounding box ottenute dall'annotazione manuale. 15
3.3 Esempio di individuazione delle zone dense tramite `BrightAreaExtractor`. I riquadri indicano le regioni identificate come zone dense, successivamente ritagliate per costituire il dataset di immagini zoom. 17
3.4 Istogramma del numero di nuclei nelle 15 immagini reali a campo intero. . 18
3.5 Istogramma della larghezza dei nuclei nelle 15 immagini reali a campo intero. 20
3.6 Istogramma dell'altezza dei nuclei nelle 15 immagini reali a campo intero. . 20
3.7 Distribuzione della larghezza dei crop. 22
3.8 Distribuzione dell'altezza dei crop. 23
3.9 Distribuzione del numero di nuclei per crop. 24
3.10 Istogramma della larghezza dei nuclei nei 715 crop delle zone dense. 25
3.11 Istogramma dell'altezza dei nuclei nei 715 crop delle zone dense. 25

4.1 Esempio di output del generatore full-image. 32
4.2 Esempio di output del generatore zoom. 33
4.3 Esempio di output del generatore di casi difficili. 34

7.1 Curve di training del modello full (YOLO26l, 250 epoche): box loss, classification loss e l1 loss su training e validation set, e metriche di precision, recall, mAP@50 e mAP@50-95 calcolate da YOLO sul validation set sintetico a ogni epoca. 50
7.2 Curve della fase di pre-training del modello zoom (YOLO26l sul dataset sintetico di crop): box loss, classification loss e l1 loss su training e validation set, e metriche di precision, recall, mAP@50 e mAP@50-95 calcolate da YOLO sul validation set sintetico ad ogni epoca. 51
7.3 Curve della fase di fine-tuning del modello zoom (YOLO26l sul dataset reale di crop, a partire dai pesi del pre-training): box loss, classification loss e l1 loss su training e validation set, e metriche di precision, recall, mAP@50 e mAP@50-95 calcolate da YOLO sul validation set reale ad ogni epoca. . . 52
7.4 Dettaglio di una zona densa della stessa immagine reale di test: il full singolo (sinistra) copre solo in parte il cluster di nuclei sovrapposti, mentre la pipeline dual-model (destra) ne rileva un numero maggiore. 55
7.5 Esempio di ammasso denso di nuclei in cui il confine tra nuclei adiacenti è visivamente ambiguo (sinistra) e la relativa annotazione manuale (destra): la scelta di quanti nuclei distinti individuare, e dove tracciarne il confine, richiede un giudizio soggettivo. 57

Elenco delle tabelle

3.1 Statistiche descrittive del numero di nuclei nelle 15 immagini reali a campo intero. 19

3.2 Statistiche descrittive delle dimensioni delle bounding box dei nuclei (altezza e larghezza congiunte), espresse in pixel. 21

3.3 Statistiche descrittive delle dimensioni dei crop delle zone dense. 22

3.4 Statistiche descrittive del numero di nuclei per crop. 22

3.5 Statistiche descrittive delle dimensioni delle bounding box dei nuclei nei crop delle zone dense (altezza e larghezza congiunte), espresse in pixel. . . 24

7.1 Metriche del modello full sul set reale (15 immagini, 11 472 nuclei annotati), al punto operativo ottimale (conf $= 0{,}6$, IoU-NMS $= 0{,}3$). 50

7.2 Metriche del modello zoom sul set reale (72 immagini/crop di test), al punto operativo ottimale (conf $= 0{,}15$, IoU-NMS $= 0{,}4$). 53

7.3 Metriche della pipeline dual-model sul set reale (15 immagini, stesso set del modello full), al punto operativo ottimale (margine $= 50\,\text{px}$, IoU-NMS di confine $= 0{,}25$). 54

7.4 Confronto tra il modello full singolo e la pipeline dual-model, sulle 15 immagini reali. 54

7.5 Confronto tra il modello precedente (YOLOv5), il modello full singolo e la pipeline dual-model, sulle stesse 15 immagini reali e con lo stesso protocollo di selezione delle soglie operative. 58

Capitolo 1

Introduzione

1.1 Contesto biologico e clinico

La valutazione dell'efficacia dei trattamenti sperimentali per le malattie neuromuscolari richiede la capacità di misurare, in modo affidabile e riproducibile, il grado di compromissione e di recupero del tessuto muscolare. Questo è particolarmente rilevante per le distrofie muscolari, un gruppo eterogeneo di patologie caratterizzate da progressiva degenerazione delle fibre muscolari, di cui la distrofia muscolare facio-scapolo-omerale (FSHD) rappresenta uno dei casi meglio caratterizzati dal punto di vista molecolare, pur restando priva di una cura definitiva.

La FSHD è una delle distrofie muscolari più diffuse e colpisce sia adulti che bambini indipendentemente dal sesso [2]. La malattia si manifesta tipicamente con debolezza progressiva dei muscoli del volto, delle spalle e delle braccia, per poi coinvolgere in modo variabile altri gruppi muscolari nel corso del tempo. Una caratteristica distintiva della FSHD è l'elevata variabilità clinica: età di esordio, velocità di progressione e gravità dei sintomi possono differire notevolmente anche tra membri della stessa famiglia, incluse coppie di gemelli monozigoti [2].

Dal punto di vista molecolare, la causa principale della FSHD è la riattivazione anomala del gene DUX4 (che codifica un fattore di trascrizione), fisiologicamente attivo solo nelle primissime fasi dello sviluppo embrionale e successivamente silenziato nella maggior parte dei tessuti adulti [2]. Nella quasi totalità dei pazienti, tale riattivazione è associata alla contrazione di una regione ripetuta di DNA (il macrosatellite D4Z4) sul cromosoma 4, che nei soggetti sani mantiene il gene DUX4 represso attraverso meccanismi epigenetici; in

una minoranza di casi, la stessa riattivazione avviene invece per mutazioni in geni coinvolti nel mantenimento di questa repressione, senza contrazione della regione ripetuta [2]. In entrambi i casi, l'esito molecolare è lo stesso: l'espressione aberrante di DUX4 nel tessuto muscolare, che innesca una serie di percorsi tossici per la cellula, tra cui l'inibizione della differenziazione miogenica, stress ossidativo, infiammazione e apoptosi incontrollata [2].

A oggi non esiste una terapia in grado di modificare il decorso della malattia, e l'unica opzione disponibile per i pazienti resta la terapia fisica di supporto [2]. La ricerca si è però concentrata negli ultimi anni sull'individuazione di strategie in grado di ridurre l'espressione o l'attività di DUX4. Un esempio recente in questa direzione è l'identificazione della proteina WDR5 come fattore necessario per l'attivazione di DUX4: il targeting farmacologico di WDR5 si è dimostrato in grado di ridurre l'espressione di DUX4 e di migliorare in vitro sia la sopravvivenza cellulare sia la capacità differenziativa di cellule muscolari derivate da pazienti FSHD [3]. Proprio la valutazione di questo tipo di effetto, ossia quanto un trattamento sperimentale migliori la capacità delle cellule muscolari di differenziarsi e fondersi in strutture multinucleate mature, richiede il calcolo di indici quantitativi a partire da immagini di microscopia, come l'indice di fusione, ossia la frazione di nuclei contenuti in strutture multinucleate rispetto al totale dei nuclei presenti nell'immagine.

1.2 Il problema della detection di nuclei densi e sovrapposti

Il calcolo automatico degli indici descritti nel paragrafo precedente richiede innanzitutto la capacità di individuare correttamente ogni singolo nucleo presente nell'immagine. I moderni sistemi di object detection basati su reti neurali individuano gli oggetti presenti in un'immagine e ne indicano la posizione tramite una bounding box, ossia il rettangolo che racchiude l'oggetto, descritto dalle coordinate di due suoi vertici opposti. Questi sistemi hanno raggiunto risultati notevoli su benchmark generalisti come MS COCO (Microsoft Common Objects in Context) [4], un dataset di riferimento con oltre 200.000 immagini annotate e 80 categorie di oggetti in scene naturali; la loro affidabilità, tuttavia, cala sistematicamente quando gli oggetti da individuare occupano una porzione minima dell'immagine: le reti neurali che costituiscono lo stato dell'arte nell'object detection faticano infatti a gestire i dettagli visivi di piccole dimensioni. Un ulteriore limite deriva dalla possibilità che uno stesso nucleo venga contato più volte, perché potrebbero essergli attribuite più bounding box parzialmente sovrapposte. Per individuare questi duplicati si ricorre all'Intersection over Union (IoU) [5],

la misura di sovrapposizione tra due bounding box definita come il rapporto tra l'area della loro intersezione e l'area della loro unione. Su questa misura si basano sia la valutazione delle predizioni, considerate corrette quando la sovrapposizione tra la predizione e l'annotazione di riferimento supera una certa soglia, sia la Non-Maximum Suppression (NMS), il meccanismo che elimina le predizioni duplicate di uno stesso oggetto [6]. Applicata a bounding box di pochi pixel, però, l'IoU penalizza in modo sproporzionato anche minimi errori di posizionamento [7].

A questa difficoltà se ne aggiunge una seconda, distinta nella causa ma riconducibile alla stessa misura: l'alta densità e la reciproca sovrapposizione degli oggetti, frequenti nelle immagini biomedicali. La NMS considera duplicate due predizioni la cui sovrapposizione supera una certa soglia e conserva soltanto quella con la confidenza più alta; quando più oggetti si trovano a stretto contatto, però, anche le bounding box di oggetti realmente distinti possono superare questa soglia, e la NMS rischia così di scambiarli per un'unica rilevazione ripetuta, sopprimendone erroneamente uno [8]. La letteratura più recente ha iniziato a trattare questo scenario come una categoria a sé stante, distinguendo esplicitamente la detection dei *dense small objects*, oggetti piccoli e sovrapposti in scene affollate, da quella più generica di piccoli oggetti isolati [7].

Questa combinazione di piccole dimensioni e alta densità è esattamente la condizione che caratterizza le immagini di microscopia a fluorescenza analizzate in questo lavoro: i nuclei cellulari occupano ciascuno una porzione ridotta del campo visivo, sono numerosi e, nelle regioni a maggiore densità cellulare, tendono a toccarsi o a sovrapporsi parzialmente, rendendo ambiguo anche per un osservatore umano il confine tra un nucleo e l'altro. Gli ammassi di nuclei rappresentano un caso limite, nel quale gli approcci di object detection convenzionali tendono a essere meno affidabili.

Affrontare questo problema richiede quindi un approccio che non si limiti ad applicare un detector standard, ma che tenga conto esplicitamente della distribuzione non uniforme della densità cellulare all'interno di una stessa immagine. Tale aspetto guida le scelte architetturali e metodologiche descritte nei capitoli successivi.

1.3 Obiettivi della tesi

L'obiettivo generale della presente tesi è sviluppare una pipeline automatizzata per l'identificazione, la localizzazione e il conteggio dei nuclei cellulari in immagini di micro-

scopia a fluorescenza, così da superare i limiti del conteggio manuale in termini di tempo richiesto e di variabilità tra operatori. Particolare attenzione è rivolta alle regioni in cui i nuclei risultano densamente aggregati o parzialmente sovrapposti. Il lavoro si colloca in continuità con una precedente tesi di laurea magistrale sullo stesso tema, svolta dalla dottoressa Zhu Yiyi [9]: ne riprende l'approccio e lo sviluppa ulteriormente.

A partire da questo obiettivo generale, il lavoro si articola nei seguenti obiettivi specifici:

1. **Sviluppo e ottimizzazione di una pipeline di object detection basata su reti neurali convoluzionali.** È stata progettata una pipeline fondata su modelli YOLO (*You Only Look Once*), orientata all'identificazione congiunta di nuclei isolati e di nuclei densamente aggregati. A questo scopo è stata adottata un'architettura a doppio modello: un primo modello opera sulle immagini a campo intero (*full*), mentre un secondo modello analizza in dettaglio le zone ad alta densità, ritagliate dall'immagine originale (*zoom*); le predizioni dei due modelli vengono infine fuse in un unico risultato.

2. **Generazione di dati sintetici per ovviare alla scarsità di dati reali annotati.** Sono stati sviluppati generatori di immagini sintetiche contenenti nuclei artificiali, i cui parametri sono calibrati sulle distribuzioni delle caratteristiche osservate nelle immagini reali. L'obiettivo è ampliare i dati disponibili per l'addestramento dei modelli, mantenendo al contempo la coerenza statistica con il dominio reale.

3. **Gestione mirata degli ammassi di nuclei più densi.** Per i casi più difficili, caratterizzati da una densità di nuclei particolarmente elevata, è stato sviluppato un generatore dedicato di immagini sintetiche che riproduce tali configurazioni.

4. **Definizione di un protocollo di valutazione adeguato al dominio.** Alle metriche standard di object detection sono state affiancate misure personalizzate, orientate al conteggio corretto dei nuclei, che in questo contesto è più rilevante della precisione di localizzazione delle bounding box. Inoltre, le soglie operative utilizzate in fase di inferenza e nella fusione delle predizioni (confidenza minima, soglia di sovrapposizione della NMS e dimensione della zona di sovrapposizione dei due modelli) sono state selezionate tramite una ricerca sistematica.

5. **Validazione della pipeline su dati reali.** Le prestazioni della pipeline sono state infine valutate su un insieme di immagini reali annotate manualmente e mai utilizzate per l'addestramento dei modelli, al fine di stimarne l'efficacia nel dominio di interesse.

1.4 Struttura del documento

Il documento segue un percorso che va dall'inquadramento del problema fino all'analisi dei risultati finali. Dopo questo capitolo introduttivo, il capitolo 2 colloca il lavoro nella letteratura esistente, ripercorrendo l'evoluzione dei modelli YOLO fino alla versione adottata in questa tesi e discutendo l'uso di dati sintetici per l'addestramento di reti di detection.

Il capitolo 3 descrive le immagini reali di microscopia a fluorescenza con colorazione DAPI (un colorante fluorescente che si lega al DNA, rendendo visibili i nuclei), i criteri seguiti per la loro annotazione manuale, la procedura di estrazione delle zone dense e le analisi descrittive condotte sui dati reali, poste alla base della calibrazione dei generatori di immagini sintetiche. Tali generatori sono presentati nel capitolo 4, insieme a una validazione visiva delle immagini prodotte.

Il capitolo 5, cuore metodologico della tesi, descrive l'architettura dual-model: la motivazione della scelta, l'addestramento dei due modelli, il meccanismo con cui le rispettive predizioni vengono combinate e il ruolo delle immagini reali annotate nell'ottimizzazione e nella valutazione.

Il capitolo 6 completa l'impianto metodologico con la definizione del protocollo di valutazione: illustra i limiti delle metriche standard di object detection in questo dominio, introduce le metriche personalizzate adottate e descrive la procedura di ricerca delle soglie operative.

La parte finale del documento è dedicata ai risultati: il capitolo 7 presenta le prestazioni ottenute dai due modelli e dalla pipeline completa, ne discute i limiti e le confronta con quelle del lavoro della dottoressa Zhu Yiyi, mentre il capitolo 8 riassume i risultati principali, ne trae le conclusioni e indica alcune possibili direzioni di sviluppo futuro.

Capitolo 2

Stato dell'arte

2.1 Reti neurali per l'object detection ed evoluzione dei modelli YOLO

Il rilevamento di oggetti (*object detection*) richiede non solo di classificare il contenuto di un'immagine, ma anche di localizzare spazialmente ciascun oggetto presente, tipicamente mediante bounding box. I primi approcci in letteratura riadattano classificatori generici: sistemi come i Deformable Parts Models (DPM) [10] impiegano una finestra scorrevole (*sliding window*), valutando il classificatore su posizioni e scale multiple dell'immagine.

Con le reti convoluzionali [11] si è affermato l'approccio a due stadi (*two-stage*), inaugurato dalla famiglia R-CNN [12]: un algoritmo di *region proposal* (es. Selective Search [13]) genera bounding box candidate, che vengono poi classificate da una CNN e raffinate tramite regressione e *non-maximum suppression*. La pipeline risultante, composta da più moduli addestrati separatamente, è lenta e complessa da ottimizzare: le prime versioni di R-CNN richiedevano oltre 40 secondi per immagine [14].

YOLO (*You Only Look Once*), proposto in [14], introduce un cambio di paradigma: anziché scomporre il rilevamento in fasi distinte, riformula l'intero problema come un unico task di regressione, in cui la rete riceve in input l'immagine e restituisce direttamente le coordinate delle bounding box e le probabilità di classe.

L'idea di base è la seguente: l'immagine viene suddivisa in una griglia $S \times S$. Ogni cella è responsabile della predizione di un oggetto il cui centro ricade all'interno della cella, e produce B bounding box (ciascuna con coordinate x, y, w, h e uno score di confidenza) più un set di probabilità di classe condizionate. Il confidence score è il prodotto tra probabilità di

presenza dell'oggetto e l'IoU tra box predetta e ground truth; moltiplicato per la probabilità di classe fornisce uno score specifico per classe. L'output finale è un tensore $S \times S \times (B \cdot 5 + C)$, con C numero di classi. Va precisato che il riferimento alla ground truth riguarda la fase di addestramento: durante il training, per ogni cella responsabile della predizione di un oggetto, il valore target del confidence score è definito proprio come l'IoU tra la bounding box predetta e quella reale, in modo da penalizzare anche le predizioni che individuano correttamente l'oggetto ma con una localizzazione imprecisa. In fase di inferenza, invece, la ground truth non è ovviamente disponibile: il confidence score è a tutti gli effetti il valore prodotto direttamente dalla rete, interpretabile come una stima della probabilità di presenza dell'oggetto combinata con la qualità attesa della localizzazione.

Essendo un'unica rete addestrata end-to-end, YOLO elimina l'ottimizzazione separata dei componenti tipica dei modelli a due stadi, con un guadagno netto in velocità (45 fps per YOLO base, 155 fps per Fast YOLO [14]) e in robustezza contro i falsi positivi di sfondo, grazie alla visione globale dell'immagine durante training e inferenza.

Il limite principale deriva dal vincolo spaziale della griglia: ogni cella predice un numero limitato di box e una sola classe, penalizzando il rilevamento di oggetti piccoli e ravvicinati il cui centro cade nella stessa cella [14].

Le versioni successive di YOLO hanno affrontato progressivamente proprio questo limite. YOLOv2 [15] introduce batch normalization [16], un classificatore ad alta risoluzione e anchor box ricavate tramite k-means clustering al posto di bounding box libere, migliorando accuratezza e recall. YOLOv3 [17] adotta il backbone Darknet-53 e predizioni multi-scala su tre livelli della rete (13×13, 26×26, 52×52): la combinazione di feature map a risoluzioni diverse migliora sensibilmente la detection di oggetti piccoli, uno dei punti deboli più critici delle versioni precedenti [18].

YOLOv4 [19] consolida l'architettura con il backbone CSPDarknet53, il neck PANet e un ampio insieme di tecniche di training (*bag of freebies/specials*) per aumentare l'accuratezza senza incidere sui tempi di inferenza. Con YOLOv5 [20], sviluppato da Ultralytics in PyTorch, il progetto abbandona il framework Darknet, scritto in C e pensato principalmente per un uso da riga di comando, in favore di PyTorch, framework ampiamente diffuso nella comunità di deep learning, con installazione tramite pip, un'API Python di alto livello per addestramento, validazione ed esportazione dei modelli, documentazione estesa e una repository attivamente mantenuta. Questa maggiore accessibilità, unita alla disponibilità di modelli pre-addestrati pronti all'uso, ne favorisce l'adozione su larga scala in ambito industriale pur

in assenza di una pubblicazione scientifica formale.

YOLOv6 [21], sviluppato da Meituan per applicazioni industriali, introduce un backbone re-parametrizzato e tecniche di quantizzazione per l'inferenza su hardware con risorse limitate; YOLOv7 [22] propone invece nuove strategie di training (*trainable bag-of-freebies*) che migliorano l'accuratezza senza alcun impatto sui tempi di inferenza. Con YOLOv8 [23] il progetto abbandona definitivamente l'approccio ad anchor box: anziché predire gli offset rispetto a un insieme di bounding box di riferimento predefinite (di dimensioni e proporzioni fissate a priori, come avveniva dalla versione 2 in poi), la rete predice direttamente le coordinate del centro e le dimensioni di ciascun oggetto, eliminando la necessità di definire e calibrare manualmente gli anchor per il dominio applicativo specifico. Viene inoltre introdotta una testa di detection disaccoppiata (*decoupled head*), in cui i rami convoluzionali responsabili della classificazione e quelli responsabili della regressione delle coordinate della bounding box sono separati anziché condividere gli stessi livelli finali: trattandosi di due task con caratteristiche differenti (la classificazione beneficia di feature semantiche, la regressione di feature spaziali precise), la separazione riduce l'interferenza reciproca tra i due obiettivi di ottimizzazione durante il training. A ciò si aggiungono nuove funzioni di loss (CIoU e Distribution Focal Loss) che migliorano ulteriormente l'accuratezza in particolare sugli oggetti di piccole dimensioni [18].

Le versioni successive proseguono su questa linea evolutiva: YOLOv9 [24] introduce il Programmable Gradient Information per limitare la perdita di informazione nei livelli profondi della rete; YOLOv10 [25] elimina per la prima volta la necessità della non-maximum suppression in fase di inferenza, rendendo la pipeline nativamente end-to-end; YOLOv11 [26] raffina ulteriormente i blocchi convoluzionali (C3k2) e introduce moduli di attenzione spaziale (C2PSA). YOLO26 [27], rilasciato da Ultralytics nel 2025 ed effettivamente impiegato nella pipeline sviluppata in questa tesi, generalizza l'inferenza end-to-end senza NMS, rimuove la Distribution Focal Loss per semplificare l'export su hardware eterogeneo e introduce un nuovo schema di loss (ProgLoss) abbinato a una tecnica di assegnazione dei target (STAL) pensata specificamente per migliorare l'accuratezza sugli oggetti di piccole dimensioni: una caratteristica particolarmente rilevante per il contesto applicativo di questa tesi.

L'andamento di questi sviluppi è riassunto efficacemente nel confronto reso disponibile da Ultralytics tra le diverse versioni e scale dei modelli, che mette a confronto numero di parametri e latenza di inferenza rispetto all'accuratezza (mAP, paragrafo 6.2.2) ottenuta

sul dataset COCO, evidenziando uno spostamento costante della frontiera costo-prestazioni verso configurazioni sempre più efficienti (figura 2.1).

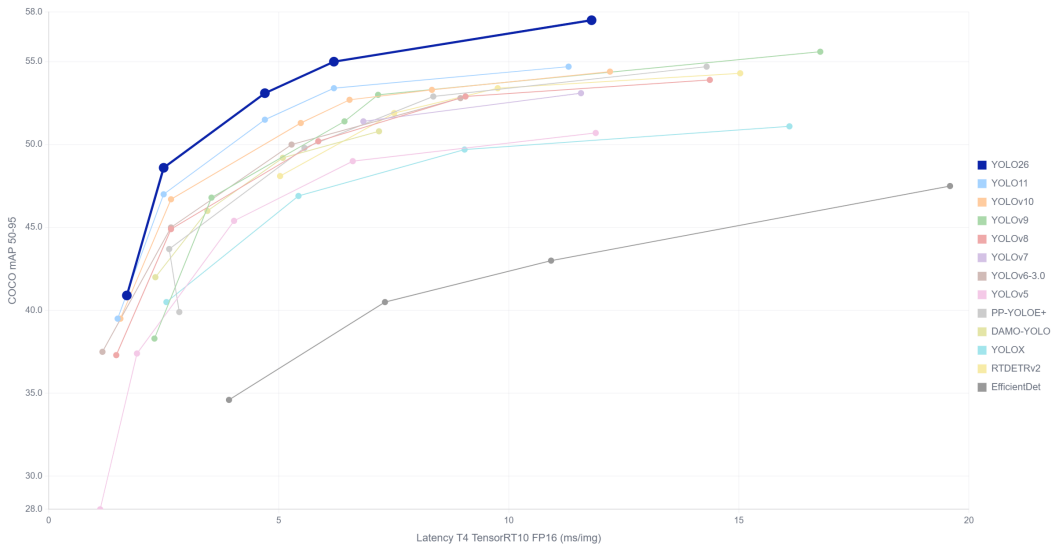


Figura 2.1: Confronto prestazionale tra le diverse versioni dei modelli YOLO in termini di latenza di inferenza e accuratezza (mAP) sul dataset COCO. Fonte: Ultralytics [1].

Questa evoluzione non elimina però del tutto il problema di partenza: la detection di oggetti piccoli e densi resta una delle sfide più critiche per l'intera famiglia di modelli single-stage, e riguarda direttamente il contesto di questa tesi, dove i nuclei cellulari nelle immagini di microscopia a fluorescenza sono spesso piccoli, numerosi e sovrapposti.

2.2 Generazione di dati sintetici per il training

Uno degli ostacoli più ricorrenti nell'applicazione del deep learning alla microscopia biomedica è la scarsità di dati annotati manualmente: l'etichettatura richiede tempo, competenza specialistica ed è particolarmente onerosa quando gli oggetti da annotare sono piccoli, numerosi o sovrapposti tra loro, come nel caso dei nuclei cellulari. La generazione di dati sintetici nasce come risposta diretta a questo collo di bottiglia, offrendo un modo per produrre grandi quantità di dati di training senza il costo dell'annotazione manuale.

Il principale vantaggio di questo approccio è il controllo totale sulla composizione della scena: è possibile determinare a piacimento densità, dimensione e grado di sovrapposizione dei nuclei, rappresentando in modo mirato anche le configurazioni più difficili, come cluster densi o oggetti di piccole dimensioni, che nei dataset reali possono essere rare o sottorappresentate. Inoltre, la maschera viene creata automaticamente, quindi non presenta gli

errori tipici dell'annotazione umana, e il volume di dati disponibile può essere scalato senza costi aggiuntivi di etichettatura.

Che questo approccio funzioni non solo in teoria ma anche in pratica è dimostrato in [28], che nel contesto della segmentazione di nuclei in volumi di microscopia a fluorescenza tridimensionale generano maschere sintetiche di nuclei, modellate come ellissoidi deformati di dimensione, orientamento e posizione casuali, e le traducono in volumi di microscopia realistici tramite un modello generativo condizionato spazialmente (SpCycleGAN [29]). Il risultato più significativo del loro lavoro è che un modello addestrato esclusivamente su dati sintetici ha ottenuto prestazioni pari o superiori rispetto a un modello addestrato anche su dati reali annotati, a conferma che la generazione sintetica può, in questo dominio applicativo, sostituire efficacemente l'annotazione manuale.

L'approccio non è tuttavia privo di limiti. Il rischio principale è il cosiddetto *domain gap*: se la sintesi non riproduce fedelmente le caratteristiche visive dei dati reali (rumore, contrasto, artefatti tipici della tecnica di acquisizione), il modello addestrato su dati sintetici rischia di non generalizzare bene in fase di inferenza su immagini reali. Infine, va notato che anche gli approcci generativi non eliminano del tutto la dipendenza dai dati reali: per determinare i parametri geometrici del generatore di maschere sintetiche (ad esempio l'intervallo di dimensioni e la quantità di nuclei) è comunque necessario disporre di un numero di immagini reali annotate, per quanto notevolmente ridotto rispetto a un dataset di training completo, da cui ricavare per ispezione visiva e quantitativa le caratteristiche da riprodurre e da utilizzare per testare la bontà dei modelli.

Gli stessi vantaggi e gli stessi limiti motivano l'interesse per la generazione di dati sintetici anche nel contesto di questa tesi.

Capitolo 3

Dati

3.1 Le immagini reali (colorazione DAPI)

Le immagini reali utilizzate in questo lavoro sono state acquisite tramite un microscopio a fluorescenza Carl Zeiss Axio Imager M2 (Zeiss, Germania), impiegando la colorazione DAPI (4',6-diamidino-2-fenilindolo), un composto fluorescente che si lega selettivamente al DNA e permette quindi di visualizzare specificamente i nuclei cellulari, distinguendoli dal resto del tessuto. Il segnale nucleare così ottenuto viene acquisito come immagine in scala di grigi, dove l'intensità di ciascun pixel riflette la concentrazione locale di DNA marcato. Nel flusso di acquisizione impiegato, questo canale viene tipicamente combinato con un secondo canale relativo alla marcatura dei miotubi, a scopo di visualizzazione congiunta, un aspetto che non incide sull'elaborazione descritta in questa tesi, incentrata esclusivamente sul canale nucleare.

Le immagini utilizzate si presentano in due tipologie: immagini a campo intero, che riproducono l'intera area osservata al microscopio, raccolte come appena descritto, e ritagli di zone ad alta densità di nuclei, estratti da queste ultime tramite un processo descritto nel paragrafo 3.3. Entrambe le tipologie provengono dalla medesima serie di acquisizioni sperimentali.

Il dataset reale annotato manualmente consta di 15 immagini a campo intero e di 715 ritagli di zone dense. La marcata differenza numerica tra le due quantità è dovuta a un vincolo pratico: l'annotazione manuale di un'immagine a campo intero, che può contenere centinaia di nuclei, richiede un tempo sensibilmente maggiore rispetto a quella di un singolo ritaglio, il quale presenta tipicamente un numero di nuclei più contenuto. Questo vincolo di

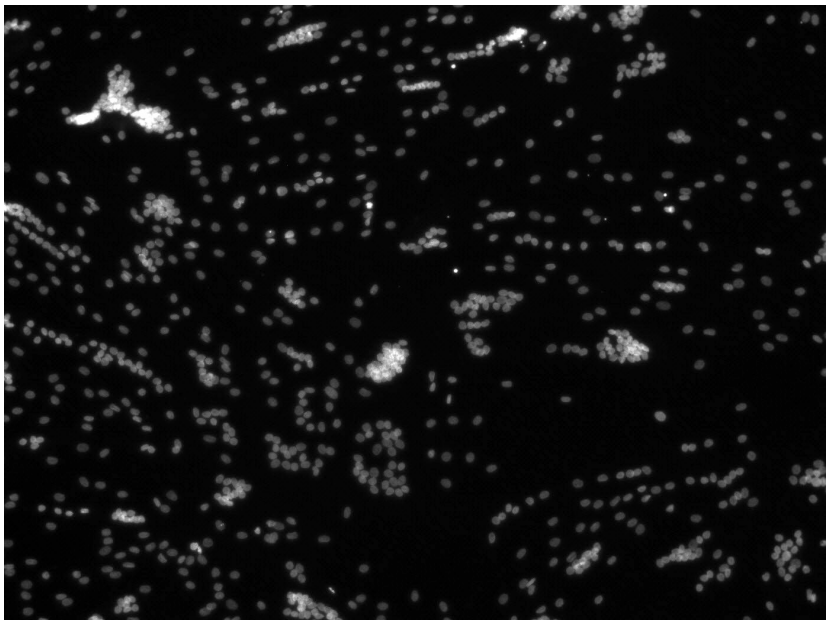


Figura 3.1: Esempio di immagine acquisita mediante microscopia a fluorescenza con colorazione DAPI. I nuclei cellulari appaiono come strutture luminose e costituiscono le immagini di partenza utilizzate in questo lavoro.

tempo ha reso impraticabile annotare manualmente un numero di immagini a campo intero comparabile a quello dei ritagli, motivando le scelte metodologiche relative alla suddivisione dei dati che verranno descritte nel capitolo 5.

3.2 Criteri di annotazione

Le annotazioni sono state realizzate in formato YOLO: per ciascun nucleo individuato manualmente nell'immagine viene registrata una singola bounding box, definita dalle coordinate del centro (x, y) e dalle dimensioni (larghezza w e altezza h), tutte e quattro normalizzate rispetto, rispettivamente, alla larghezza e all'altezza dell'immagine. Tutte le annotazioni afferiscono a un'unica classe, denominata *nucleo*: indipendentemente da eventuali differenze di forma, intensità del segnale di fluorescenza o stato del nucleo, ogni bounding box annotata identifica genericamente la presenza di un nucleo cellulare, senza distinzioni ulteriori. Questa scelta riflette l'obiettivo del lavoro, che è la localizzazione e il conteggio dei nuclei presenti nell'immagine e non la loro classificazione in sottocategorie biologiche o morfologiche. Nel formato YOLO, questa classe è identificata dal valore 0, riportato come primo elemento di ogni riga del file di annotazione .txt; seguono le coordinate del centro della box e le sue dimensioni (larghezza e altezza).

A titolo esemplificativo, il listato 3.1 riporta le prime cinque righe di un file di annotazione e la figura 3.2 mostra un'immagine reale del dataset con le bounding box risultanti dall'annotazione manuale dei nuclei.

Listato 3.1: Prime cinque righe di un file di annotazione in formato YOLO.

```
0 0.924628 0.747148 0.019776 0.026458
0 0.971897 0.765401 0.022290 0.022616
0 0.935773 0.706815 0.025520 0.016853
0 0.937388 0.674638 0.015816 0.022616
0 0.953562 0.670338 0.017254 0.019691
```

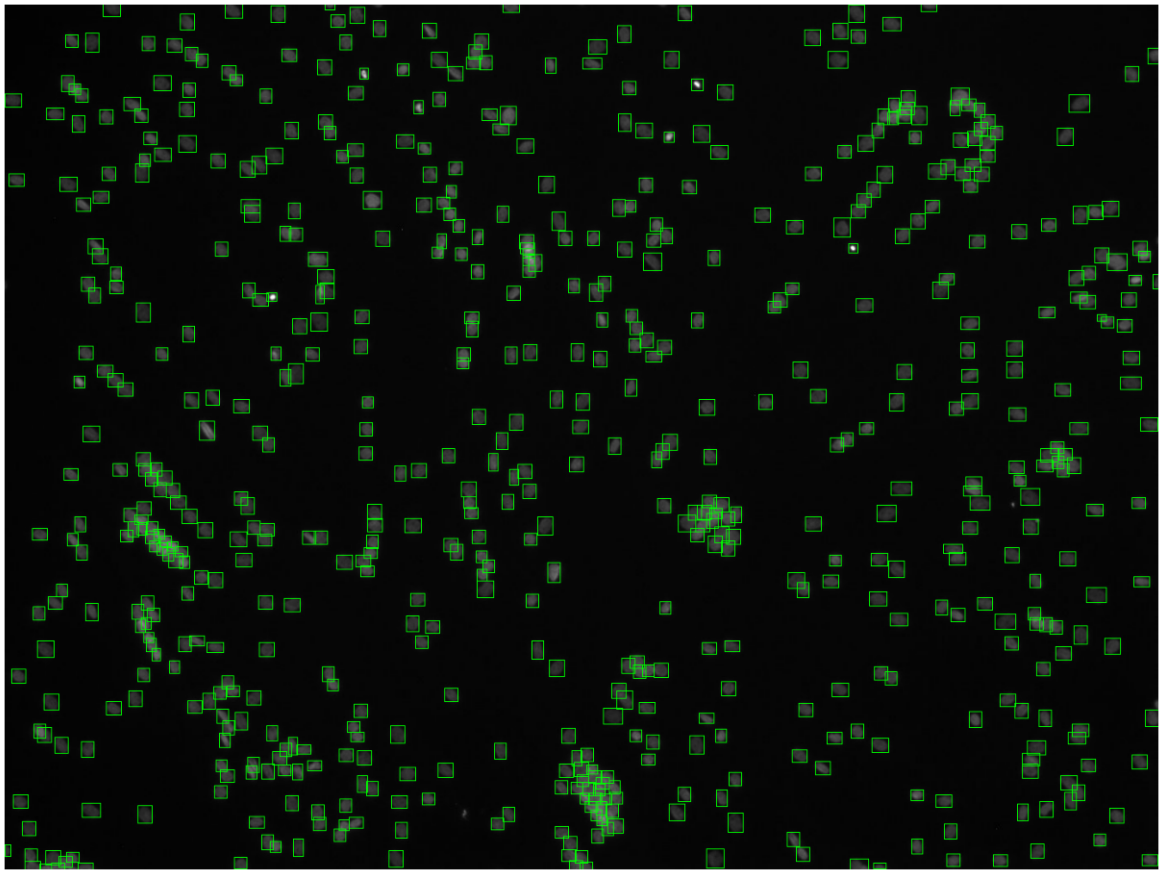


Figura 3.2: Esempio di immagine reale con le bounding box ottenute dall'annotazione manuale.

Il criterio generale seguito nell'annotazione è l'assegnazione di una bounding box distinta a ciascun nucleo visivamente distinguibile, tracciata in modo da racchiudere strettamente l'estensione apparente del nucleo nell'immagine. Questo stesso criterio è stato applicato in modo coerente sia alle immagini a campo intero sia ai ritagli delle zone dense,

dato che questi ultimi condividono con le prime la medesima risoluzione e le medesime condizioni di acquisizione, differenziandosi unicamente per l'area di campo inquadrata.

Nelle regioni a densità cellulare più elevata, dove i nuclei si trovano parzialmente sovrapposti o a stretto contatto, l'annotazione richiede un giudizio più articolato, basato sull'osservazione di discontinuità nella forma o nell'intensità del segnale fluorescente per distinguere nuclei adiacenti. In questi casi, la separazione tra nuclei distinti può risultare intrinsecamente ambigua anche per un osservatore umano: le implicazioni di questa ambiguità sono discusse più diffusamente nel paragrafo 7.4.2.

3.3 Estrazione delle zone dense (BrightAreaExtractor)

L'architettura dual-model presentata nel capitolo 5 richiede che le zone dell'immagine caratterizzate da un'elevata concentrazione di nuclei vengano identificate ed elaborate separatamente rispetto al resto del campo microscopico, coerentemente con la sfida discussa nel paragrafo 1.2. A tale scopo è stato sviluppato uno strumento dedicato, denominato `BrightAreaExtractor`, il cui compito è individuare automaticamente, all'interno di ciascuna immagine a campo intero, le regioni ad alta densità di nuclei e restituirle come ritagli separati.

Il principio di funzionamento si basa su un'osservazione empirica relativa alla colorazione DAPI: nelle regioni in cui numerosi nuclei si trovano ravvicinati o parzialmente sovrapposti, la somma dei segnali fluorescenti emessi da ciascun nucleo produce un'intensità luminosa complessiva superiore rispetto alle zone a densità cellulare più bassa. La luminosità locale dell'immagine costituisce quindi un proxy efficace della densità di nuclei, che non richiede l'identificazione preliminare dei singoli nuclei per essere sfruttato.

Concretamente, l'estrazione procede attraverso i seguenti passaggi:

1. l'immagine viene convertita in scala di grigi;
2. viene applicata una sogliatura binaria, che classifica ciascun pixel come appartenente o meno a una regione luminosa in base a una soglia di intensità prefissata;
3. sulla maschera binaria risultante viene eseguita un'operazione di individuazione dei contorni (*contour detection*, tramite la funzione `findContours` di OpenCV [30]): l'algoritmo raggruppa i pixel luminosi tra loro adiacenti in componenti connesse e

ne ricostruisce il contorno esterno, ovvero la sequenza di punti che ne delimita il perimetro. Il risultato di questo passaggio è quindi un insieme di contorni distinti, uno per ciascuna regione luminosa presente nella maschera, trattati come oggetti separati nei passaggi successivi;

4. le regioni con area inferiore a una soglia minima vengono scartate, in modo da escludere piccole aree isolate non rilevanti ai fini dell'analisi;

5. per ciascuna regione superstite viene calcolato il rettangolo di delimitazione (bounding rectangle), utilizzato per ritagliare la corrispondente porzione dall'immagine originale.

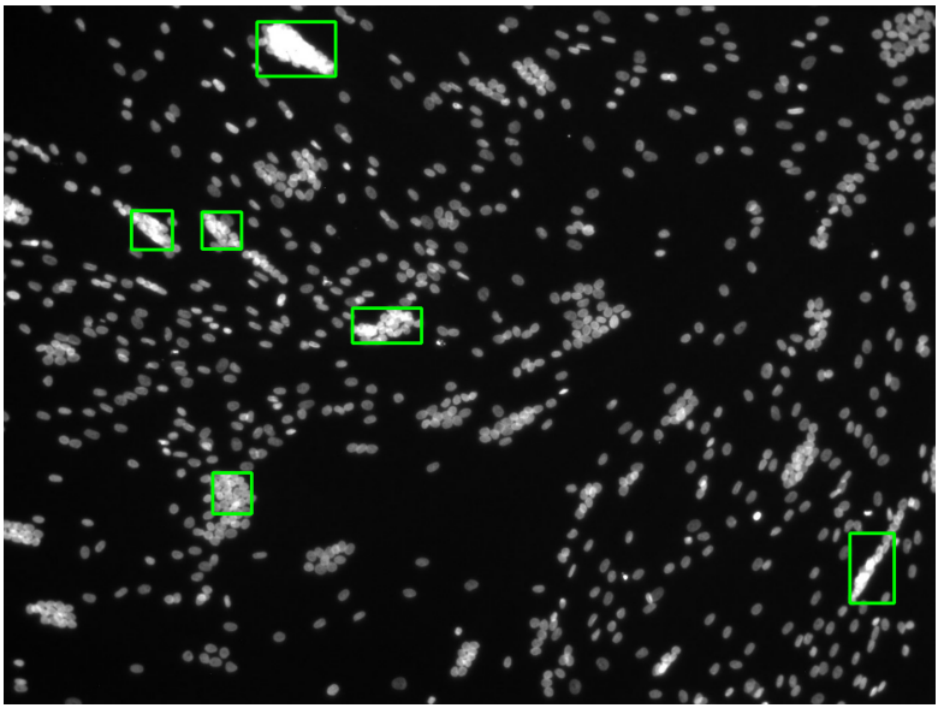


Figura 3.3: Esempio di individuazione delle zone dense tramite `BrightAreaExtractor`. I riquadri indicano le regioni identificate come zone dense, successivamente ritagliate per costituire il dataset di immagini zoom.

I due parametri che regolano il processo, la soglia di luminosità e l'area minima, sono stati fissati rispettivamente a 150 (su una scala 0–255) e 3000 pixel quadrati. Tali valori sono stati determinati empiricamente, tramite verifica visiva dei risultati prodotti su un campione di immagini, senza ricorrere a una procedura di ottimizzazione sistematica.

L'applicazione di questo procedimento a ciascuna delle immagini a campo intero disponibili produce, per ogni immagine, un numero variabile di ritagli: uno per ciascuna

zona densa individuata, incluso il caso in cui non ne venga rilevata alcuna. La figura 3.3 mostra un esempio di immagine con le zone dense individuate dal `BrightAreaExtractor`, evidenziate dai relativi riquadri. Sono questi ritagli, una volta annotati manualmente secondo i criteri descritti nel paragrafo 3.2, a costituire il dataset di immagini zoom utilizzato nel resto del lavoro, le cui caratteristiche statistiche sono riportate nel paragrafo 3.5.

3.4 Analisi descrittiva delle immagini full

Al fine di calibrare in modo statisticamente fondato il generatore di immagini sintetiche che verrà descritto nel capitolo 4, è stata condotta un'analisi descrittiva delle immagini reali a campo intero disponibili. Per ciascuna delle 15 immagini annotate sono stati estratti, a partire dai rispettivi file di annotazione, il numero di nuclei presenti e le dimensioni delle relative bounding box. Le distribuzioni ottenute, riportate nei paragrafi seguenti, hanno costituito il riferimento empirico per la definizione dei parametri del generatore sintetico, garantendo che le immagini artificiali prodotte riproducessero fedelmente i parametri osservati nei dati reali.

3.4.1 Distribuzione del numero di nuclei per immagine

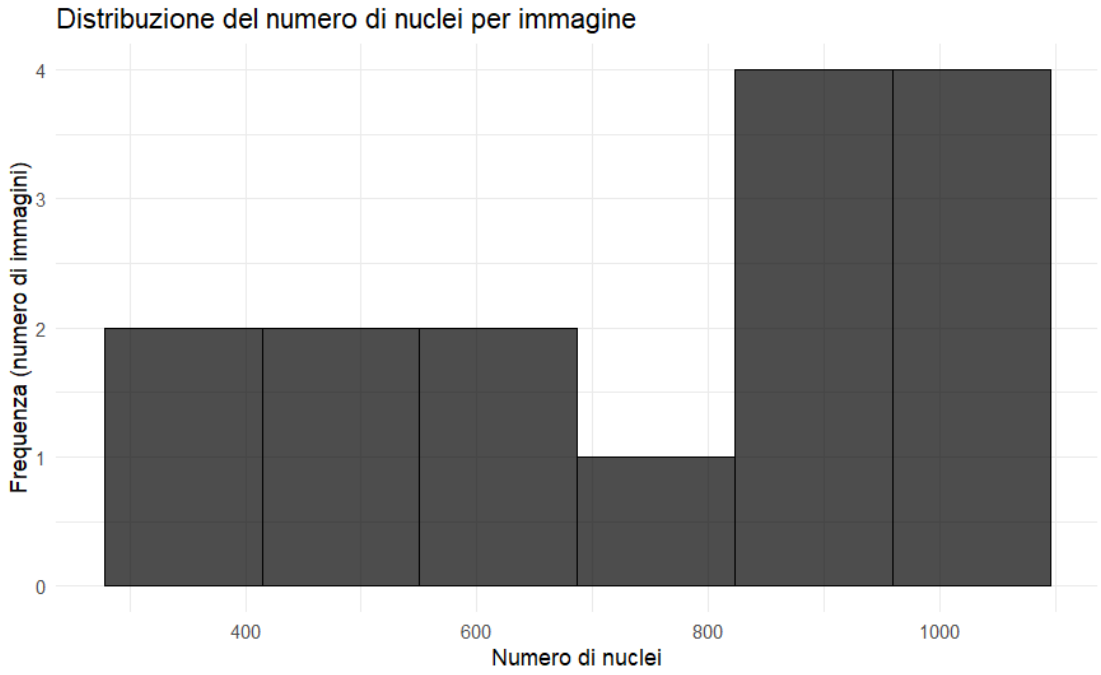


Figura 3.4: Istogramma del numero di nuclei nelle 15 immagini reali a campo intero.

Tabella 3.1: Statistiche descrittive del numero di nuclei nelle 15 immagini reali a campo intero.

Statistica	**Valore**
Numero di immagini	15
Media	764,8
Deviazione standard	234,7
Minimo	346
Mediana	856
Massimo	1028

Come riportato nella tabella 3.1 e mostrato dall'istogramma in figura 3.4, le immagini a campo intero contengono mediamente 764,8 nuclei, con una deviazione standard pari a 234,7. Il numero di nuclei varia da un minimo di 346 a un massimo di 1028, evidenziando una discreta variabilità tra le immagini.

La distribuzione osservata è stata utilizzata come riferimento per la definizione del numero di nuclei da generare nelle immagini sintetiche. In particolare, dall'ispezione dell'istogramma non emerge una forma funzionale chiaramente riconoscibile. Inoltre, la disponibilità di sole 15 immagini reali rende poco giustificata l'assunzione di una specifica distribuzione parametrica. Per questo motivo, nel generatore sintetico il numero di nuclei per immagine è stato campionato da una distribuzione uniforme nell'intervallo compreso tra il minimo e il massimo osservati nei dati reali, ossia $\mathscr{U}(346; 1028)$.

3.4.2 Distribuzione delle dimensioni dei nuclei

Per caratterizzare le dimensioni dei nuclei presenti nelle immagini reali sono state analizzate separatamente le distribuzioni delle altezze e delle larghezze delle relative bounding box, espresse in pixel. I due istogrammi sono riportati in figura 3.5 e figura 3.6. Dall'osservazione delle distribuzioni emerge un andamento sostanzialmente analogo tra altezza e larghezza, senza differenze evidenti nella forma delle due distribuzioni. Considerata inoltre la natura dei nuclei e la necessità di adottare una parametrizzazione semplice per il generatore sintetico, le due misure sono state quindi considerate congiuntamente.

A questo scopo, le osservazioni relative ad altezza e larghezza sono state riunite in un unico dataset, sul quale sono state calcolate le statistiche descrittive riportate nella

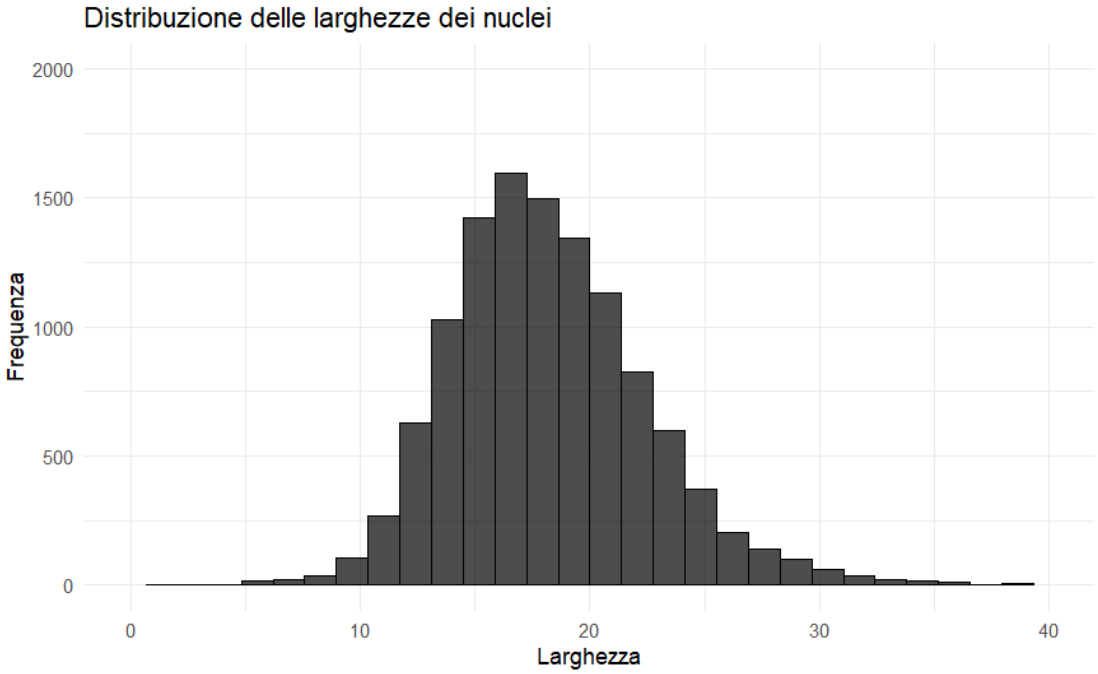


Figura 3.5: Istogramma della larghezza dei nuclei nelle 15 immagini reali a campo intero.

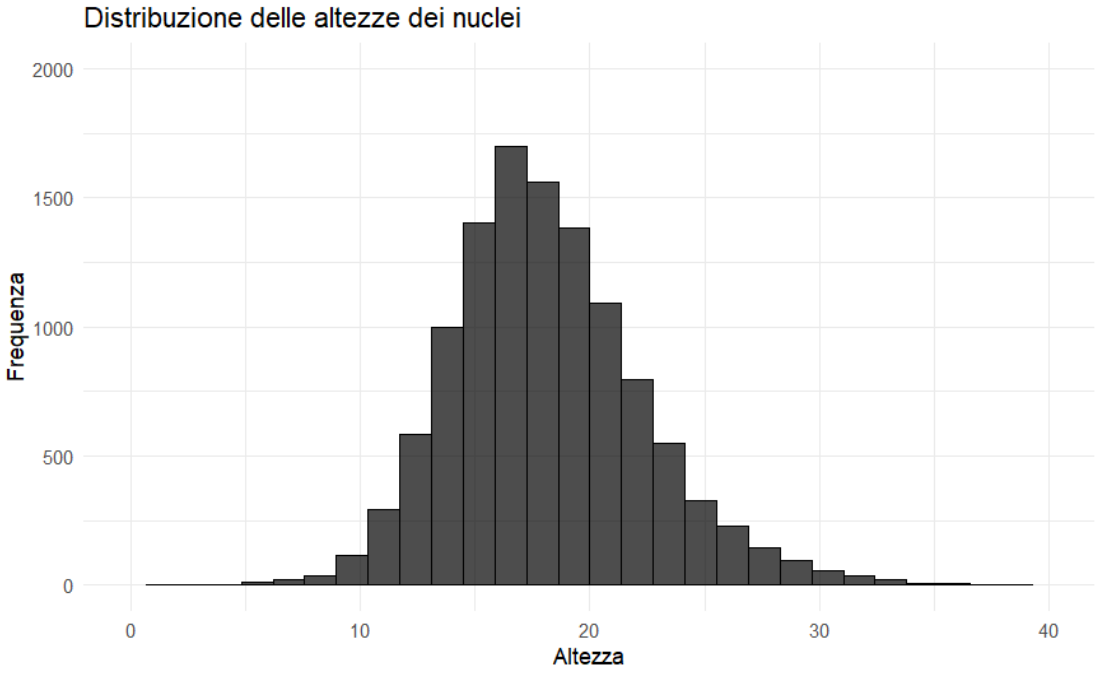


Figura 3.6: Istogramma dell'altezza dei nuclei nelle 15 immagini reali a campo intero.

Tabella 3.2: Statistiche descrittive delle dimensioni delle bounding box dei nuclei (altezza e larghezza congiunte), espresse in pixel.

Statistica	**Valore**
Media	18,18
Deviazione standard	4,22
Mediana	17,80

tabella 3.2. La dimensione media risulta pari a 18,18 pixel, con una deviazione standard di 4,22 pixel.

Gli istogrammi evidenziano un andamento compatibile con una distribuzione normale, senza particolari strutture o multimodalità. Sulla base di questa osservazione, la dimensione dei nuclei nel generatore sintetico è stata campionata da una distribuzione normale parametrizzata utilizzando la media e la deviazione standard stimate dai dati reali, ossia $\mathcal{N}(18,18;\ 4,22^2)$.

3.5 Analisi descrittiva dei crop di immagini

Un'analisi analoga è stata condotta sui ritagli delle zone ad alta densità, estratti dalle immagini reali secondo la procedura descritta nel paragrafo 3.3. A differenza delle immagini a campo intero, i ritagli non presentano dimensioni fisse, poiché la loro estensione dipende dall'area della zona densa identificata in ciascuna immagine. Per questo motivo, oltre alla distribuzione del numero di nuclei e delle loro dimensioni, è stata valutata anche la distribuzione delle dimensioni del ritaglio stesso. Anche in questo caso, le statistiche ricavate hanno guidato la calibrazione del relativo generatore sintetico.

3.5.1 Distribuzione delle dimensioni del crop

È stata analizzata la distribuzione di larghezza e altezza dei 715 crop disponibili, riportata in tabella 3.3 e negli istogrammi di figura 3.7 e figura 3.8.

Larghezza e altezza mostrano valori medi simili tra loro (rispettivamente 77,51 e 75,78 pixel). L'osservazione degli istogrammi suggerisce un andamento approssimativamente normale per entrambe le variabili. Questi parametri hanno costituito il riferimento

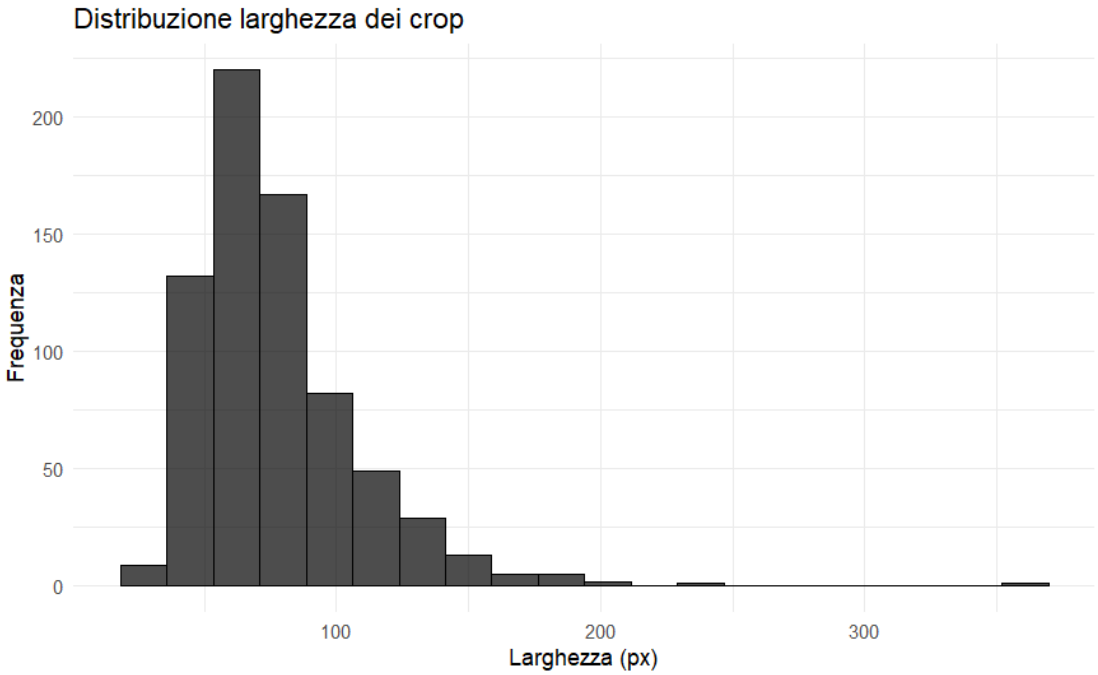


Figura 3.7: Distribuzione della larghezza dei crop.

Variabile	Media	Dev. std.	Min	Mediana	Max
Larghezza crop (px)	77,51	31,28	27	70	361
Altezza crop (px)	75,78	29,68	27	69	242

Tabella 3.3: Statistiche descrittive delle dimensioni dei crop delle zone dense.

empirico per la calibrazione del generatore di crop sintetici, che utilizza due distribuzioni normali distinte per larghezza e altezza, presentato nel capitolo 4.

3.5.2 Distribuzione del numero di nuclei per crop

È stata analizzata la distribuzione del numero di nuclei annotati all'interno di ciascuno dei 715 crop, riportata in tabella 3.4 e nell'istogramma di figura 3.9.

Tabella 3.4: Statistiche descrittive del numero di nuclei per crop.

Statistica	Valore
Media	17,39
Deviazione standard	9,51
Mediana	15

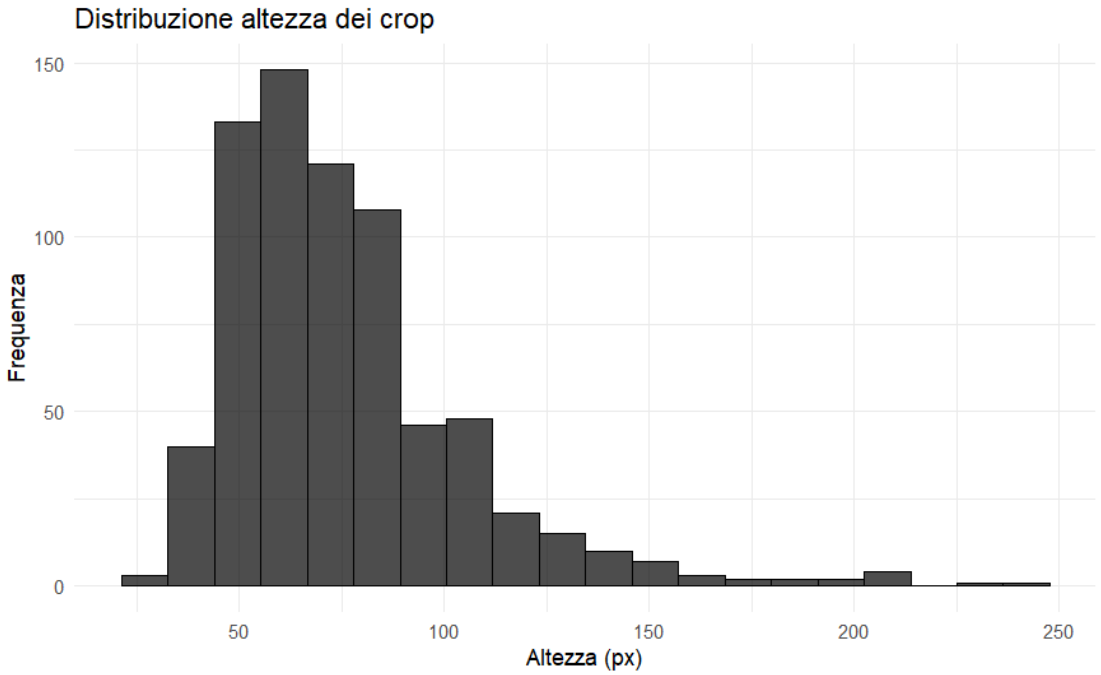


Figura 3.8: Distribuzione dell'altezza dei crop.

L'osservazione dell'istogramma suggerisce un andamento approssimativamente normale, con una media di 17,39 nuclei per crop e una deviazione standard di 9,51. Questa distribuzione ha costituito il riferimento per la calibrazione del numero di nuclei generato dal generatore sintetico.

3.5.3 Distribuzione delle dimensioni dei nuclei

Analogamente a quanto fatto per le immagini a campo intero, sono state analizzate separatamente le distribuzioni delle altezze e delle larghezze delle bounding box dei nuclei annotati nei crop delle zone dense, riportate in figura 3.10 e figura 3.11. Anche in questo caso, l'osservazione delle due distribuzioni non evidenzia differenze sostanziali di forma tra altezza e larghezza, per cui le due misure sono state nuovamente considerate congiuntamente, secondo la stessa logica adottata nel paragrafo 3.4.2.

Le osservazioni relative ad altezza e larghezza sono state riunite in un unico dataset, sul quale sono state calcolate le statistiche descrittive riportate nella tabella 3.5. La dimensione media risulta pari a 15,62 pixel, con una deviazione standard di 3,13 pixel, valori distinti da quelli ottenuti per le immagini a campo intero (18,18 e 4,22 pixel rispettivamente). Questa differenza è verosimilmente riconducibile al fatto che i crop, essendo per costruzione ritagliati dalle zone a maggiore densità cellulare, tendono a contenere nuclei parzialmente

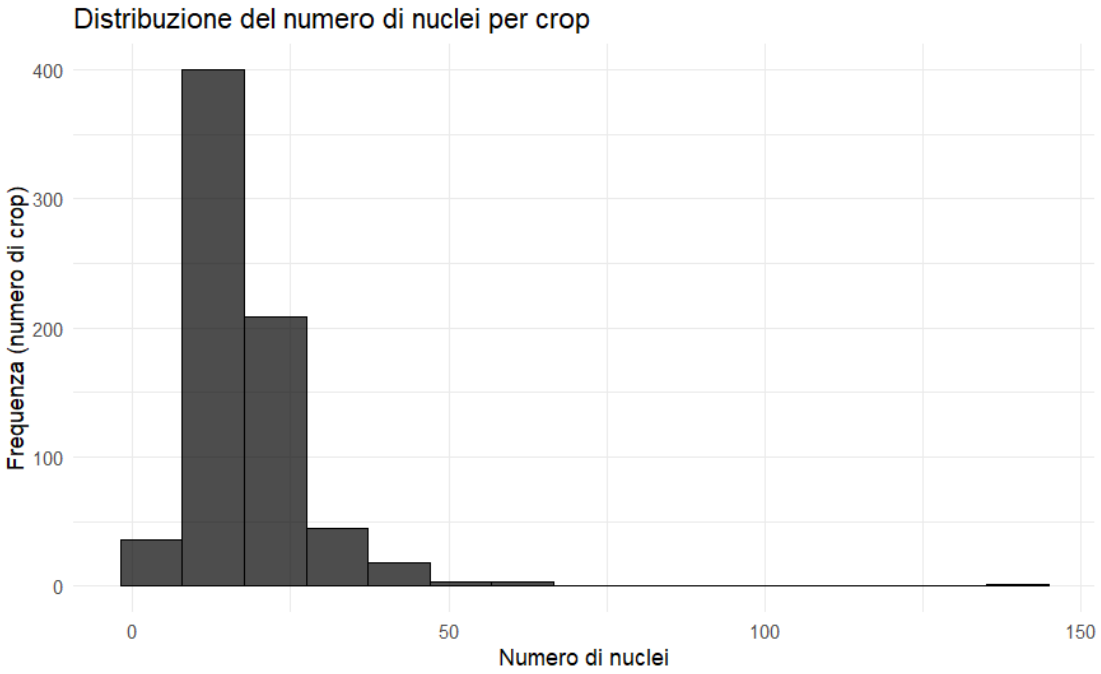


Figura 3.9: Distribuzione del numero di nuclei per crop.

Tabella 3.5: Statistiche descrittive delle dimensioni delle bounding box dei nuclei nei crop delle zone dense (altezza e larghezza congiunte), espresse in pixel.

Statistica	**Valore**
Media	15,62
Deviazione standard	3,13
Mediana	15,60

sovrapposti o a stretto contatto tra loro: in queste condizioni, la porzione di nucleo effettivamente distinguibile e delimitabile con una bounding box può risultare più contenuta rispetto a un nucleo isolato, riflettendosi in una dimensione media annotata leggermente inferiore.

Per questo motivo, i due generatori sintetici (immagini a campo intero e crop delle zone dense) sono stati calibrati separatamente su parametri distinti, anziché condividere la medesima distribuzione: nel generatore dei crop, la dimensione dei nuclei è stata quindi campionata da una distribuzione normale (individuata a seguito dell'analisi visiva dell'istogramma) parametrizzata sulle statistiche osservate specificamente in questo dataset, ossia $\mathcal{N}(15,62;\ 3,13^2)$.

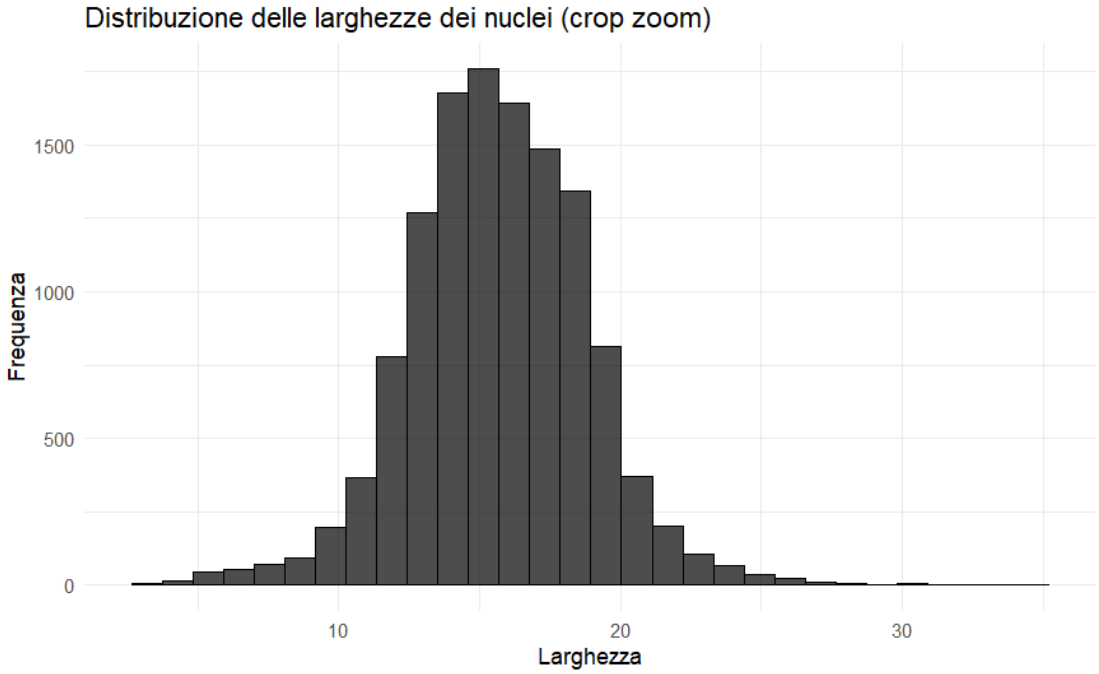


Figura 3.10: Istogramma della larghezza dei nuclei nei 715 crop delle zone dense.

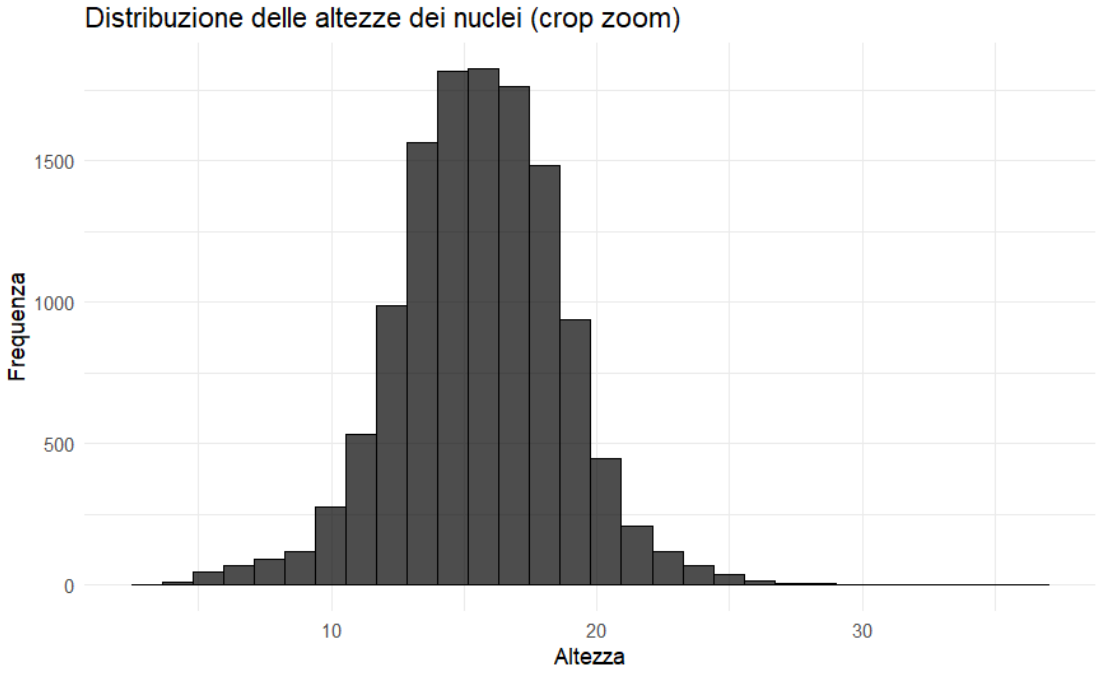


Figura 3.11: Istogramma dell'altezza dei nuclei nei 715 crop delle zone dense.

Capitolo 4

Generazione di immagini sintetiche

Per addestrare la pipeline dual-model sono stati sviluppati tre generatori di immagini sintetiche, ciascuno mirato a un'esigenza specifica della pipeline. Il **generatore full-image** (paragrafo 4.1) e il **generatore zoom** (paragrafo 4.2) condividono lo stesso principio di fondo: i rispettivi parametri di generazione sono derivati dall'analisi statistica di immagini reali etichettate, in modo da riprodurre fedelmente le caratteristiche osservate nei dati veri. Il primo produce immagini sintetiche a piena risoluzione utilizzate per il training del modello full, che si occupa della detection sulle regioni a densità di nuclei più bassa; il secondo produce crop sintetici utilizzati per il pre-training del modello zoom, responsabile della detection sulle regioni dense individuate dal `BrightAreaExtractor`. Infine, il **generatore di casi difficili** (paragrafo 4.3) nasce in risposta a una sottoperformance osservata proprio su queste configurazioni più dense: producendo crop in cui i nuclei vanno a sovrapporsi estremamente, viene utilizzato per fare oversampling mirato di tali casi nel training del modello zoom.

Le immagini prodotte dai tre generatori sono state sottoposte a una validazione visiva, riportata al termine del capitolo (paragrafo 4.4), volta a verificarne qualitativamente la plausibilità prima dell'impiego nel training.

4.1 Generatore full-image

Il generatore full-image produce immagini sintetiche a piena risoluzione (1388×1040 pixel, le stesse dimensioni delle immagini reali) utilizzate per il training del modello full. Lo sfondo viene generato come rumore gaussiano, mentre ciascun nucleo è modellato come un'ellisse ruotata di dimensione casuale, disegnata su un layer separato che viene infine

sommato allo sfondo. Il numero di nuclei per immagine viene campionato uniformemente entro l'intervallo osservato nei dati reali, in linea con il principio di calibrazione statistica descritto in apertura del capitolo.

A ciascun nucleo viene inoltre aggiunta una texture interna generata come rumore, e all'immagine finale viene applicata una sfocatura gaussiana complessiva, per riprodurre l'effetto di sfocatura ottica tipico delle immagini acquisite al microscopio. Le annotazioni vengono salvate in formato YOLO (classe unica "nucleo"), con la bounding box calcolata a partire dall'estensione geometrica dell'ellisse, ingrandita di un fattore 1,3 per compensare l'alone di sfocatura non incluso nella sagoma esatta del nucleo.

4.1.1 Cluster lineari ed ellittici

I nuclei reali non si distribuiscono nell'immagine in modo uniformemente casuale, ma tendono a organizzarsi in pattern riconoscibili: allineamenti lungo strutture fibrose del tessuto muscolare oppure aggregati localizzati in regioni più dense. Per riprodurre questa organizzazione, il generatore definisce due geometrie di cluster distinte, disegnando la maggioranza dei nuclei al loro interno mentre la parte restante viene distribuita in modo uniforme sull'intera immagine.

I cluster **lineari** sono definiti da un segmento di lunghezza e orientamento casuali; i nuclei assegnati al cluster vengono posizionati campionando un punto lungo il segmento e applicando uno scostamento perpendicolare con distribuzione gaussiana, ottenendo così un allineamento di nuclei con una dispersione laterale controllata.

I cluster **ellittici** sono invece definiti da un centro e da due semiassi di lunghezza casuale (non necessariamente uguali, per evitare cluster perfettamente circolari); i nuclei vengono posizionati al loro interno tramite rejection sampling, campionando punti nel rettangolo che circoscrive l'ellisse e accettando solo quelli che ricadono effettivamente al suo interno.

Un parametro di forza del clustering regola la proporzione complessiva di nuclei generati all'interno di un cluster rispetto a quelli dispersi casualmente, mentre i nuclei appartenenti a un cluster ricevono un incremento di intensità rispetto agli altri, per riprodurre la maggiore luminosità osservata nelle regioni dense delle immagini reali.

4.1.2 Gestione dell'overlap tra nuclei

Le regioni dense delle immagini reali contengono frequentemente nuclei che si toccano o si sovrappongono parzialmente: si tratta esattamente dei casi più critici per la detection, ed è quindi necessario che il generatore sia in grado di riprodurli piuttosto che evitarli sistematicamente.

Il controllo sull'overlap avviene su due livelli distinti. In fase di posizionamento, un controllo di collisione confronta la distanza tra il centro del nucleo candidato e i centri di tutti i nuclei già posizionati con la somma dei rispettivi raggi, corretta da un margine di distanza minima regolabile; tale margine può essere impostato anche a un valore negativo, consentendo così una sovrapposizione controllata tra nuclei adiacenti invece di imporre una separazione rigida. In fase di rendering, quando la patch di un nuovo nucleo viene fusa nel layer condiviso, i pixel nelle regioni di sovrapposizione vengono combinati tramite il massimo delle intensità anziché per somma, evitando saturazioni innaturali della luminosità.

4.2 Generatore delle immagini zoom

Il generatore delle immagini zoom riutilizza gli stessi principi del generatore full-image descritto nel paragrafo precedente: nuclei modellati come ellissi ruotate disegnate su un layer separato, sfondo gaussiano, gestione dell'overlap tramite fusione a massimo, sfocatura gaussiana finale e annotazioni in formato YOLO. La differenza principale, descritta nel dettaglio nel sottoparagrafo seguente, è che qui l'immagine non ha una dimensione fissa ma viene generata con dimensioni diverse ad ogni chiamata.

4.2.1 Dimensioni variabili del crop

A differenza del generatore full-image, che opera su un canvas di dimensione fissa, il generatore zoom produce crop di larghezza e altezza variabili, campionate da distribuzioni normali troncate (per evitare dimensioni eccessivamente piccole) calibrate sulla variabilità osservata nei crop reali estratti dal `BrightAreaExtractor`, che per loro natura hanno forma e dimensione non uniformi a seconda della regione densa individuata. Questa variabilità dimensionale si ripercuote su tutta la geometria interna del generatore: i margini utilizzati per il posizionamento dei cluster, il raggio massimo dei cluster ellittici e la lunghezza dei cluster lineari vengono vincolati dinamicamente alle dimensioni effettive del crop generato,

in modo da evitare che i cluster eccedano i bordi dell'immagine o vengano generati con proporzioni incoerenti rispetto a un canvas particolarmente piccolo.

4.2.2 Parametri di clustering

Poiché ogni ritaglio rappresenta già una sotto-regione densa dell'immagine originale, i parametri di clustering vengono ritarati rispetto al generatore full-image. La proporzione di nuclei generati all'interno di un cluster è molto più alta (quasi la totalità, contro circa due terzi nel generatore full-image) poiché un crop zoom cattura per definizione agglomerati di nuclei compressi, in cui gli elementi isolati sono marginali. Prevalgono inoltre i cluster di tipo ellittico rispetto a quelli lineari, privilegiando aggregati compatti coerenti con la scala ridotta del ritaglio, e il numero di cluster per immagine si riduce a una o due unità, sufficienti a riempire un'area molto più contenuta rispetto a quella dell'immagine full.

4.3 Generatore di casi difficili

Il generatore di casi difficili produce un crop di dimensione fissa più ampia rispetto al generatore zoom ordinario (circa 160×160 pixel, contro i 78×76 precedenti), costruito in due fasi: un blob centrale densissimo di nuclei sovrapposti, seguito da alcuni nuclei sparsi isolati nel resto del crop. La logica di rendering, gestione dell'overlap, sfocatura finale e annotazione riutilizza integralmente quanto già descritto per gli altri due generatori.

4.3.1 Motivazione: sotto-rappresentazione degli ammassi densi

Le distribuzioni statistiche alla base del generatore zoom ordinario producono raramente le configurazioni più estreme di densità, che restano eventi di coda statisticamente rari nel campionamento casuale. Nelle fasi iniziali di sperimentazione, i modelli addestrati su questi dati hanno effettivamente mostrato una sottoperformance proprio su questi casi, portando alla decisione di introdurre un generatore dedicato che ne facesse oversampling mirato, anziché affidarsi alla sola probabilità che simili configurazioni emergessero spontaneamente dal campionamento statistico.

4.3.2 Design del blob ellittico centrale

Il blob è modellato come un'ellisse quasi circolare, posizionata al centro del crop con un piccolo scostamento casuale rispetto al centro esatto, per evitare che il modello apprenda un pattern artificioso legato a una posizione sempre identica. Al suo interno viene collocato un numero di nuclei molto elevato (circa 90) rispetto all'area occupata (raggio di circa 30 pixel), permettendo un overlap estremamente marcato tra nuclei adiacenti tramite una soglia di distanza minima fortemente negativa, per riprodurre gli ammassi più compatti osservati nelle regioni più dense delle immagini reali. La resa visiva del blob è calibrata per la massima uniformità: intensità vicina alla saturazione e texture interna ridotta, in modo da ottenere una macchia pressoché omogenea in cui i singoli nuclei risultano a malapena distinguibili: lo stesso fenomeno che rende questi casi difficili da riconoscere per il detector. Nonostante l'indistinguibilità visiva, ciascun nucleo del blob riceve comunque una bounding box individuale.

A completare il crop, un piccolo numero di nuclei sparsi viene collocato al di fuori del blob. Questo garantisce che il crop non sia composto unicamente dal blob denso, ma includa anche qualche nucleo ben distinguibile ai margini, più fedele a come si presenta realmente il contorno di un ammasso denso nelle immagini di microscopia.

4.4 Validazione visiva

A conclusione del capitolo, le figure 4.1, 4.2 e 4.3 mostrano un esempio rappresentativo dell'output di ciascuno dei tre generatori, a scopo di verifica qualitativa delle caratteristiche descritte nei paragrafi precedenti.

Nell'immagine prodotta dal generatore full-image (figura 4.1) sono riconoscibili sia cluster lineari, con nuclei allineati lungo una direzione preferenziale, sia cluster ellittici più compatti, insieme a un certo numero di nuclei dispersi uniformemente sul resto del canvas, coerentemente con il bilanciamento tra nuclei strutturati e nuclei liberi descritto in precedenza.

Nell'immagine prodotta dal generatore zoom (figura 4.2) si nota innanzitutto la dimensione del crop, non più fissa come nel generatore full-image ma variabile: la visibilità dei singoli pixel ne è una conseguenza diretta, poiché crop di dimensioni ridotte, visualizzati alla stessa scala degli altri, risultano più ingranditi e quindi più sgranati. Questo effetto,

assente nelle immagini del generatore full-image, che hanno dimensioni fisse e quindi una risoluzione di visualizzazione costante, è dunque un indizio visivo della natura variabile delle dimensioni del crop. Al suo interno si osserva un'elevata densità di nuclei, in linea con l'elevata proporzione di nuclei clusterizzati caratteristica di questo generatore. I nuclei restano tuttavia ancora abbastanza distinguibili l'uno dall'altro.

Nell'immagine prodotta dal generatore di casi difficili (figura 4.3), pur presentando anch'essa un ammasso centrale di nuclei, la sovrapposizione tra i nuclei risulta molto più marcata rispetto al caso zoom: il blob appare come una macchia pressoché omogenea in cui i singoli nuclei sono a stento distinguibili, a differenza dell'ammasso più "leggibile" del generatore zoom.

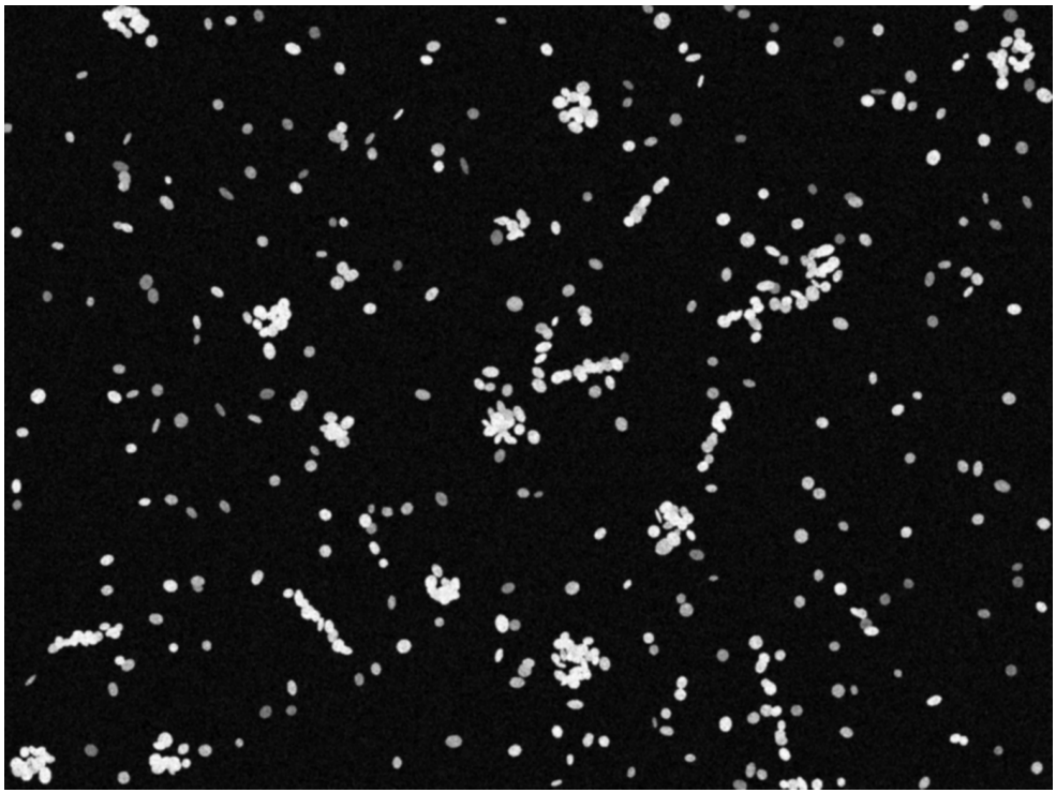


Figura 4.1: Esempio di output del generatore full-image.

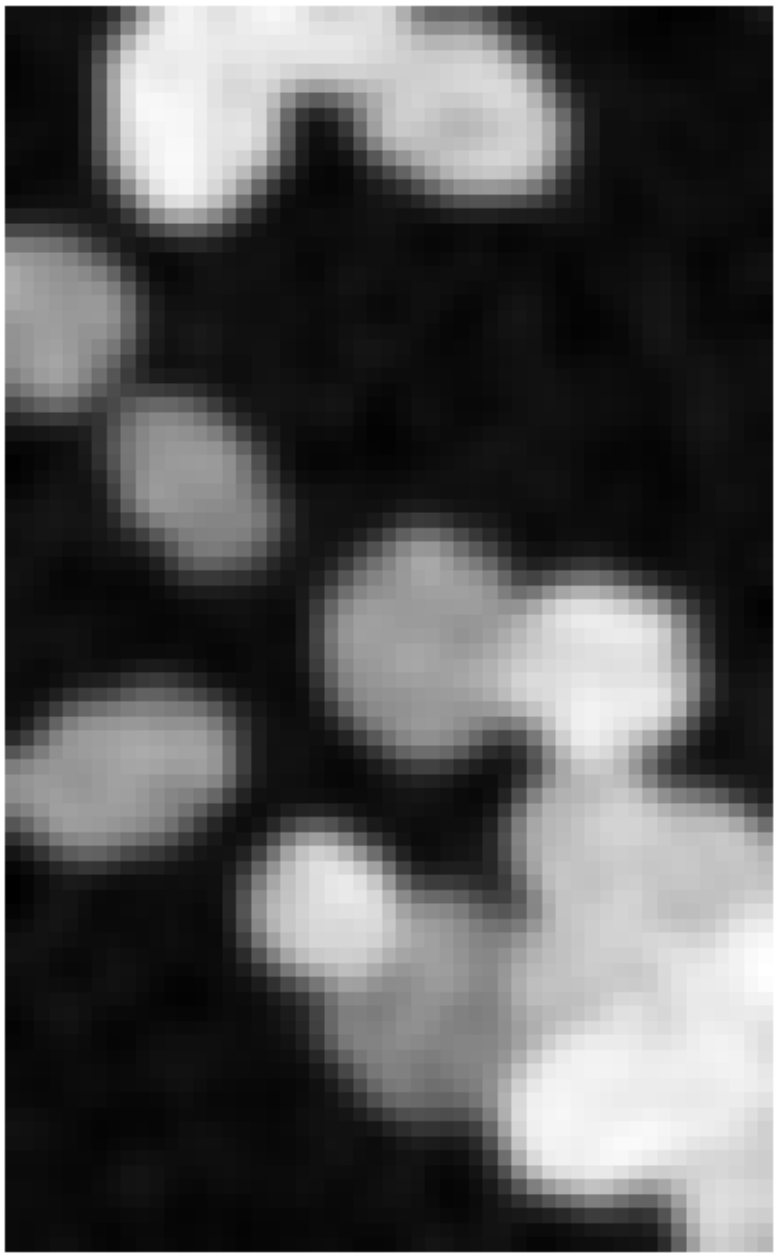


Figura 4.2: Esempio di output del generatore zoom.

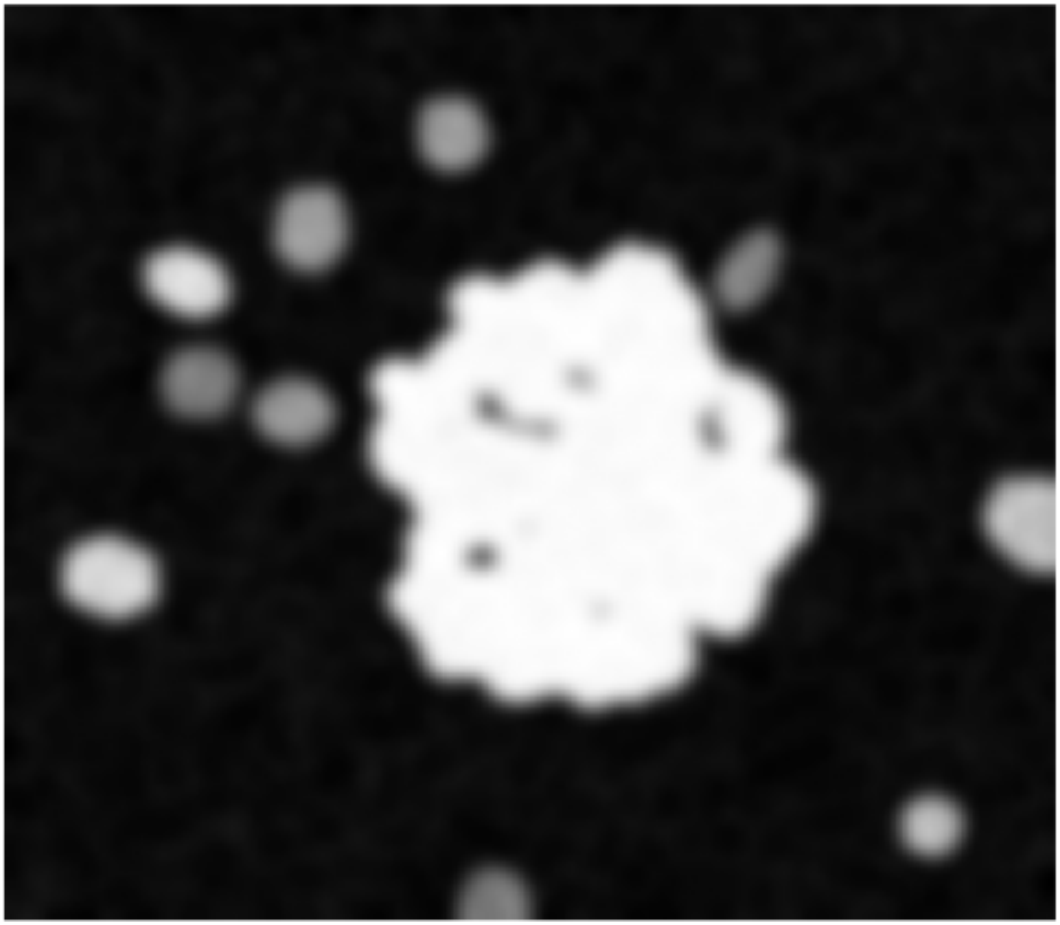


Figura 4.3: Esempio di output del generatore di casi difficili.

Capitolo 5

Architettura della pipeline

In questo capitolo viene descritta l'architettura della pipeline sviluppata: la motivazione alla base della scelta di un'architettura a doppio modello, l'addestramento dei due modelli (full e zoom), il meccanismo con cui le rispettive predizioni vengono combinate e il ruolo delle immagini reali annotate nell'ottimizzazione e nella valutazione finale.

5.1 Approccio generale

Questo paragrafo introduce la logica generale della pipeline: le ragioni che hanno portato alla scelta di un'architettura a doppio modello, e una panoramica del flusso completo, dal training dei singoli modelli fino alla valutazione finale.

5.1.1 Motivazione dell'architettura dual-model

Un modello di detection generico, addestrato ed eseguito sull'immagine intera, fatica a identificare correttamente nuclei ravvicinati o sovrapposti nelle regioni a densità più elevata. Per questo motivo si è scelto di affiancare al modello full-image un secondo modello, specializzato nell'analisi delle zone dense, usato in modo mirato sulle regioni identificate dal `BrightAreaExtractor` (paragrafo 3.3). Le predizioni dei due modelli vengono infine combinate in una fase di fusione (paragrafo 5.4).

L'obiettivo di questa architettura è migliorare la capacità di rilevamento nelle zone dense senza penalizzare le prestazioni nelle zone sparse, che restano affidate al solo modello full-image.

5.1.2 Panoramica del flusso: training, fine-tuning, fusione e valutazione

Il flusso della pipeline si articola in quattro fasi. Il modello full viene addestrato esclusivamente su immagini sintetiche, senza fine-tuning sul reale (paragrafo 5.2). Il modello zoom viene invece pre-addestrato su dati sintetici e poi sottoposto a fine-tuning sulle immagini reali, con un esperimento aggiuntivo di oversampling sui casi difficili (paragrafo 5.3). Le predizioni dei due modelli vengono quindi combinate in una fase di fusione (paragrafo 5.4), e il risultato viene infine valutato sulle 15 immagini reali annotate (paragrafo 5.5).

5.2 Training del modello full

Il modello full è un YOLO26l, inizializzato dai pesi pre-addestrati e sottoposto a training completo, senza congelamento di layer (freeze $= 0$), sul dataset sintetico di immagini full, composto da 3 000 immagini di training, 350 di validazione e 150 di test. Il training viene condotto a risoluzione 1024×1024 sia in fase di training sia di validazione, per un massimo di 250 epoche, con arresto anticipato[1] (patience $= 30$) e dimensione del batch[2] determinata automaticamente (batch $= -1$).

La disponibilità di 15 immagini reali annotate poteva spingere per l'uso di queste per il fine-tuning del modello, ma ciò non è stato effettuato per due motivi. Il primo è la scarsità di dati reali annotati: le sole 15 immagini disponibili sono un numero insufficiente per un fine-tuning sicuro, che rischierebbe di portare a overfitting. Il secondo è la necessità di preservare l'integrità di questo set come dato di test: utilizzarlo anche per il fine-tuning del modello full ne comprometterebbe la validità come insieme non visto in fase di valutazione finale della pipeline.

5.3 Training e fine-tuning del modello zoom

Il dataset reale di crop a disposizione per il modello zoom è di dimensioni contenute (715 immagini in totale, suddivise in 572 di training, 71 di validazione e 72 di test),

[1] Il training viene interrotto se non si riscontrano miglioramenti nelle performance per 30 epoche consecutive.

[2] Il batch size è il numero di immagini che la rete elabora insieme prima di ogni aggiornamento dei pesi: valori più piccoli producono aggiornamenti più frequenti ma rumorosi, valori più grandi aggiornamenti più stabili ma richiedono un maggiore utilizzo di memoria GPU. Il valore -1 indica che la dimensione viene scelta automaticamente in base alla memoria disponibile.

insufficiente per un addestramento da zero. Il modello zoom viene quindi addestrato in due fasi: un pre-training sul dataset sintetico di crop, seguito da un fine-tuning sul dataset reale.

Nella fase di pre-training, il modello (YOLO26l) viene addestrato sul dataset sintetico di crop, composto da 1 800 immagini di training (di cui 800 di casi difficili), 270 di validazione (120 difficili) e 163 di test (63 difficili). Il training viene condotto a risoluzione 640×640, senza congelamento di layer (freeze $= 0$), per un massimo di 200 epoche, con arresto anticipato (patience $= 30$) e batch determinato automaticamente (batch $= -1$), la stessa logica di addestramento del modello full.

Nella fase di fine-tuning, che riparte dai pesi ottenuti nel pre-training, il modello viene addestrato sulla porzione di training del dataset reale di crop per un massimo di 80 epoche, con arresto anticipato (patience $= 20$) e batch determinato automaticamente (batch $= -1$), mantenendo la stessa risoluzione (640×640).

Il backbone viene parzialmente congelato (freeze $= 10$) e il learning rate ridotto (lr0 $= 0{,}0005$) per limitare un problema tipico del transfer learning su dataset di piccole dimensioni: aggiornare tutti i pesi di una rete già pre-addestrata usando poche immagini espone al rischio di *catastrophic forgetting*, ossia la perdita delle feature generali apprese in precedenza a favore di un adattamento eccessivo (overfitting) alle sole immagini disponibili. Nelle reti convoluzionali, gli strati più vicini all'input tendono ad apprendere feature di basso livello (bordi, texture, forme elementari), in gran parte trasferibili tra domini visivamente simili, mentre gli strati più profondi codificano rappresentazioni più specifiche del task e del dominio di addestramento [6]. Congelando i primi dieci layer si preservano le feature di basso livello già apprese sul dataset sintetico (presumibilmente ancora valide sul dominio reale, data la somiglianza visiva tra le due tipologie di immagine) e si vincola l'aggiornamento ai soli strati più profondi, quelli più sensibili alle differenze specifiche tra sintetico e reale (rumore, illuminazione, texture di colorazione). Analogamente, il learning rate ridotto contiene l'ampiezza degli aggiornamenti dei pesi non congelati: con un training set piccolo, le stime del gradiente calcolate a ogni batch sono più rumorose e meno rappresentative della distribuzione reale dei dati, per cui passi di aggiornamento ampi rischierebbero di allontanare i pesi dal punto di partenza già efficace del pre-training, invece di affinarlo gradualmente.

5.4 Fusione delle predizioni

In questo paragrafo viene descritto come le predizioni prodotte dal modello full e dal modello zoom vengono combinate in un unico insieme di detection per immagine.

5.4.1 Classificazione delle detection rispetto alle zone dense

Il modello full viene eseguito sull'intera immagine, incluse le zone dense: non è escluso a priori dall'inferenza su queste regioni. Il modello zoom viene invece eseguito solo sui ritagli corrispondenti alle zone dense individuate dal `BrightAreaExtractor` (paragrafo 3.3), e le sue detection vengono poi riportate in coordinate dell'immagine originale.

Ogni detection, di entrambi i modelli, viene classificata in base alla distanza del centro della propria bounding box dal confine della zona densa più vicina, usando un margine di tolleranza (`border_margin_px`, scelto tramite il grid search del paragrafo 6.4.2). Si distinguono così tre categorie: è *outside_far* se il centro dista più del margine di tolleranza all'esterno di ogni zona densa, *inside_far* se dista più del margine di tolleranza all'interno della zona densa che lo contiene, *border* in tutti gli altri casi, ossia quando il centro cade entro il margine di tolleranza dal confine, da entrambi i lati. Questa terza categoria definisce di fatto una cornice attorno al confine di ciascuna zona densa.

5.4.2 Assegnazione diretta delle detection *outside_far* e *inside_far*

Per le detection classificate come *outside_far* o *inside_far*, l'assegnazione è diretta e non richiede alcun confronto tra i due modelli: le detection del modello full classificate come *outside_far* vengono mantenute così come sono, quelle classificate come *inside_far* vengono scartate, perché quella regione è territorio del modello zoom, addestrato specificamente su di essa. Simmetricamente, le detection del modello zoom classificate come *inside_far* vengono mantenute direttamente.

5.4.3 Non-Maximum Suppression nella cornice di confine

Le detection di entrambi i modelli classificate come *border* vengono raccolte in un unico pool comune e sottoposte a Non-Maximum Suppression. Questa NMS è limitata al solo pool di confine: non viene eseguita alcuna NMS né sull'intera immagine, né tra le detection già assegnate direttamente nel passaggio precedente (paragrafo 5.4.2).

Le detection del pool vengono ordinate dalla confidence più alta alla più bassa e poi esaminate una per una: ciascuna viene tenuta, a meno che non si sovrapponga troppo (IoU oltre la soglia `border_iou_nms`, trovata anch'essa con il grid search del paragrafo 6.4.2) a una detection già tenuta in precedenza.

5.5 Utilizzo delle 15 immagini reali annotate

Le 15 immagini reali annotate non vengono utilizzate in fase di training o fine-tuning di alcuno dei due modelli, né per ricavarne crop di addestramento per il modello zoom, il cui fine-tuning sul reale si basa su ritagli provenienti da altre immagini annotate separatamente. Il loro utilizzo è limitato a due scopi: l'ottimizzazione degli iperparametri operativi (le soglie di confidenza e di IoU-NMS di ciascun modello, il margine e la soglia IoU della NMS di confine, paragrafo 5.4.3) e la valutazione finale della pipeline stessa. Il criterio con cui queste soglie vengono scelte a partire dai risultati della grid search è descritto nel paragrafo 6.4.

Capitolo 6

Protocollo di valutazione

Il capitolo descrive il protocollo adottato per valutare le prestazioni della pipeline sviluppata. Si discute dapprima perché le metriche standard di object detection, basate sul protocollo COCO, risultino poco adeguate al dominio di questa tesi (paragrafo 6.1), per poi presentare le metriche effettivamente adottate, sia quelle mutuate dalla letteratura standard sia quelle orientate al conteggio introdotte per superarne i limiti (paragrafo 6.2), e la scelta di implementarle da zero anziché affidarsi agli strumenti nativi di Ultralytics (paragrafo 6.3). Il capitolo si chiude con la procedura seguita per la ricerca degli iperparametri operativi della pipeline.

6.1 Limiti delle metriche COCO standard nel dominio

Il protocollo di validazione standard di YOLO, basato sulle metriche COCO (mAP, mAP@50, mAP@75), presenta alcuni limiti quando applicato a questo dominio.

In primo luogo, la mAP (paragrafo 6.2.2) aggrega le prestazioni del modello su tutto lo spettro di soglie di confidence, il valore minimo di score al di sopra del quale una predizione viene considerata valida, anziché fissarne una specifica. In fase di utilizzo, però, il modello opera necessariamente a un'unica soglia operativa fissata, la stessa per ogni predizione: la mAP, essendo una sintesi sull'intero spettro di soglie possibili, non fornisce quindi un'indicazione diretta di come il sistema si comporti in corrispondenza di quella soglia specifica.

In secondo luogo, il protocollo COCO è stato concepito per la detection multiclasse generica, su un numero elevato di categorie eterogenee tra loro. Il compito affrontato in questa tesi riguarda invece un'unica classe, caratterizzata da oggetti piccoli, spesso densi e

sovrapposti, uno scenario poco rappresentativo del contesto per cui le metriche COCO sono state originariamente pensate.

Il limite più rilevante, tuttavia, riguarda cosa queste metriche premiano. Metriche come mAP@75, in particolare, danno molto peso alla precisione della localizzazione della bounding box, richiedendo una sovrapposizione elevata con il ground truth perché una detection sia considerata corretta. In questo dominio, però, un lieve disallineamento del box rispetto al nucleo non costituisce un problema pratico: ciò che conta ai fini applicativi è il conteggio corretto dei nuclei, ossia non perderne (falsi negativi) e non contarne alcuni due volte (duplicati/falsi positivi). Una detection imprecisa nella localizzazione ma corretta ai fini del conteggio ha, in questo contesto, più valore di una localizzazione perfetta che però produce un conteggio errato.

Infine, va notato che l'indipendenza della mAP dalla soglia di confidence e l'uso di una soglia IoU di NMS fissa non sono limiti dovuti a trascuratezza, ma scelte di design intenzionali del protocollo COCO: permettono di confrontare in modo equo modelli e architetture diverse su un benchmark generico, senza che il confronto dipenda da quale soglia operativa ciascuno sceglierebbe in produzione, e senza rischiare di ottimizzare la soglia di NMS sul singolo test set. In questa tesi, tuttavia, l'obiettivo non è confrontare architetture generiche, ma costruire uno strumento con un'unica configurazione operativa che verrà effettivamente utilizzata: non interessa quindi sapere come si comporta il modello su tutto lo spettro di soglie possibili, ma quanto è accurato il conteggio alla soglia di confidence e di NMS con cui il sistema verrà davvero usato. Per questo motivo ha senso, nel caso di questa tesi, cercare esplicitamente tali parametri operativi e riportare le metriche in quel punto specifico, anziché limitarsi ai valori aggregati su tutte le soglie.

Questi limiti motivano l'adozione di metriche aggiuntive orientate al conteggio (paragrafo 6.2.3) e la necessità di una ricerca dedicata dei parametri operativi (paragrafo 6.4).

6.2 Metriche adottate

Questo paragrafo presenta le metriche utilizzate per valutare la pipeline: precision, recall e F1, calcolate alla soglia di confidence operativa; la mAP@50, riportata per confrontabilità con la letteratura di object detection; MAE e bias, che misurano direttamente l'errore di conteggio.

6.2.1 F1, Precision e Recall

In un problema di detection, ogni predizione del modello può essere classificata in due modi rispetto al ground truth: vero positivo (*true positive*, TP), se corrisponde correttamente a un oggetto realmente presente, oppure falso positivo (*false positive*, FP), se è una detection "in più" che non corrisponde a nessun oggetto reale. Un oggetto reale che il modello non è riuscito a rilevare viene invece classificato come falso negativo (*false negative*, FN). A differenza di un problema di classificazione, in detection non esiste un equivalente utile di "vero negativo": non ha senso contare le regioni dell'immagine correttamente non segnalate come oggetto, dato che sono innumerevoli.

A partire da TP, FP e FN si definiscono due metriche complementari. La **precision** è la frazione di detection prodotte dal modello che corrispondono effettivamente a un nucleo reale:

$$\text{Precision} = \frac{TP}{TP + FP}$$

Misura quindi l'affidabilità delle detection: una precision bassa indica molti falsi allarmi. La **recall** è invece la frazione di nuclei realmente presenti che il modello è riuscito a trovare:

$$\text{Recall} = \frac{TP}{TP + FN}$$

Misura la completezza del rilevamento: una recall bassa indica che molti nuclei vengono persi.

Le due metriche sono tra loro in contrapposizione: abbassando la soglia di decisione[1] il modello produce più detection, tipicamente aumentando la recall (si perdono meno nuclei) ma abbassando la precision (aumentano i falsi positivi); alzando la soglia avviene l'opposto. Per riassumere questo compromesso in un unico valore si usa l'**F1-score**, la media armonica di precision e recall:

$$F1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

A differenza della media aritmetica, la media armonica penalizza fortemente lo squilibrio tra le due metriche: un modello con precision alta ma recall molto bassa (o viceversa) ottiene comunque un F1 basso, che risulta alto solo quando precision e recall sono entrambe alte.

[1] Molti classificatori binari producono una classificazione applicando una soglia ad un output numerico, se l'output è superiore alla soglia viene attribuita una categoria, altrimenti l'altra. La scelta della soglia può portare a migliorare la precision a scapito della recall o viceversa.

Nell'applicazione a questa pipeline, la classificazione di ciascuna predizione come TP o FP, e di ciascun ground truth come rilevato o mancato (FN), avviene tramite un matching greedy: le predizioni vengono ordinate per confidence decrescente e ciascuna viene associata al miglior ground truth ancora libero, purché la sovrapposizione (IoU) con esso superi una soglia fissa. Il valore definitivo di questa soglia verrà riportato nel capitolo 7.

Precision, recall e F1 non vengono calcolate separatamente per ciascuna immagine e poi mediate tra le immagini, ma a partire dal conteggio di TP, FP e FN sommato (*pooled*) sull'intero dataset. Questa scelta dà così più peso alle immagini con un numero maggiore di nuclei, che pesano quindi proporzionalmente di più sul risultato finale, seguendo l'obiettivo di misurare la correttezza del conteggio complessivo piuttosto che la performance media per singola immagine.

Precision, Recall e F1 vengono calcolate alla soglia di confidence operativa, anch'essa riportata nel capitolo 7, anziché aggregate su tutto lo spettro di soglie come nel calcolo della mAP. F1 viene adottata come metrica operativa primaria per la ricerca di tali soglie.

6.2.2 mAP@50

Mentre precision, recall e F1 vengono misurate a un'unica soglia di confidence operativa, la mAP (*mean Average Precision*) valuta il modello lungo l'intero spettro delle soglie di confidence, senza fissarne una. L'idea alla base è la seguente: si ordinano tutte le predizioni del dataset per confidence decrescente e le si "accetta" una alla volta seguendo questo ordine, il che equivale ad abbassare progressivamente la soglia di confidence da 1 a 0. Per ogni punto di questa sequenza si accumulano il numero di veri positivi (TP) e falsi positivi (FP) visti fino a quel punto, e da questi si ricavano una precision e un recall cumulativi, costruendo così, punto per punto, la curva precision-recall del modello sull'intero spettro di soglie.

L'*Average Precision* (AP) è, in sostanza, l'area sottesa a questa curva. Nella pratica viene approssimata con l'interpolazione a 101 punti adottata dal protocollo COCO: per 101 livelli di recall equispaziati tra 0 e 1, si prende la precision massima raggiunta a un recall maggiore o uguale a quel livello, e si media il risultato sui 101 punti. Questa interpolazione rende la curva monotona e riduce l'effetto di oscillazioni locali dovute a singole predizioni.

Il suffisso "@50" indica la soglia IoU fissata a 0,5 per stabilire se una predizione

corrisponde correttamente (TP) a un ground truth durante la costruzione della curva: si tratta dello stesso criterio di matching già introdotto per F1, Precision e Recall, qui però applicato lungo tutto lo spettro di soglie di confidence anziché a una soglia fissa. Coerentemente con quanto discusso nel paragrafo 6.1, non vengono qui riportate le varianti più severe sulla localizzazione (mAP@75) né la sua restrizione ai soli oggetti piccoli (mAP_small), poiché premiano una precisione di posizionamento del box che non è l'obiettivo applicativo di questa tesi.

Come per le altre metriche adottate, anche la curva precision-recall alla base della mAP@50 viene costruita in modo *pooled* sull'intero dataset, anziché calcolata immagine per immagine e poi mediata, dando così più peso alle immagini con un numero maggiore di nuclei.

La mAP@50 viene riportata principalmente per confrontabilità con la letteratura standard di object detection; i risultati di questa tesi vengono tuttavia interpretati soprattutto alla luce di F1 e delle metriche di conteggio (paragrafo 6.2.3), più direttamente legate all'obiettivo applicativo discusso nel paragrafo 6.1.

6.2.3 MAE e bias di conteggio

Per ciascuna immagine si definisce l'errore di conteggio come la differenza, con segno, tra il numero di predizioni prodotte dal modello e il numero di nuclei annotati nel ground truth:

$$e_i = n_{\text{pred},i} - n_{\text{gt},i}$$

Un valore positivo indica che il modello ha sovra-contato i nuclei in quell'immagine, uno negativo che li ha sotto-contati.

Da questa quantità si ricavano due metriche complementari. Il **MAE** (*Mean Absolute Error*) è la media, sull'intero dataset, del valore assoluto dell'errore di conteggio:

$$\text{MAE} = \frac{1}{N}\sum_{i=1}^{N} |e_i|$$

il quale misura quanto, in media, il conteggio del modello si discosta da quello reale su una singola immagine, indipendentemente dalla direzione dell'errore. Il **bias** è invece la media dello stesso errore senza valore assoluto:

$$\text{Bias} = \frac{1}{N}\sum_{i=1}^{N} e_i$$

indica se il sistema tende sistematicamente a sovra-contare (bias positivo) o sotto-contare (bias negativo) i nuclei. Le due metriche insieme danno un'informazione che nessuna delle due dà da sola: un MAE alto con bias vicino a zero indica errori frequenti ma bilanciati tra sovra- e sotto-conteggio; un MAE e un bias di grandezza simile indicano invece un errore sistematico in un'unica direzione.

A differenza di F1, Precision, Recall e mAP@50, che vengono calcolate in modo *pooled* sull'intero dataset, MAE e bias sono qui la media degli errori per-immagine, con ciascuna immagine pesata allo stesso modo indipendentemente dal numero di nuclei che contiene. La scelta è coerente con la domanda a cui queste due metriche vogliono rispondere: non "qual è l'errore di conteggio complessivo su tutto il dataset", ma "quanto ci si aspetta di sbagliare tipicamente su una singola immagine", dunque, pesare ogni immagine allo stesso modo, indipendentemente dalla sua densità, è la scelta naturale.

Di tutte le metriche adottate, MAE e bias sono quelle più direttamente legate all'obiettivo applicativo discusso nel paragrafo 6.1: misurano infatti l'errore di conteggio in sé, non la qualità di localizzazione dei box.

6.3 Implementazione custom delle metriche

Le metriche di questo capitolo non vengono calcolate con `model.val()` di Ultralytics: quest'ultimo valuta le predizioni di un singolo modello confrontandole con le annotazioni del proprio dataset di validazione o test. L'oggetto della valutazione finale di questa tesi è invece l'output della pipeline dual-model nel suo complesso: le predizioni del modello full sull'immagine intera e quelle del modello zoom sui ritagli delle zone dense, riportate in coordinate dell'immagine originale e combinate secondo la procedura di fusione descritta nel paragrafo 5.4. Si tratta quindi delle detection congiunte di due modelli distinti, un oggetto che `model.val()` non è pensato per gestire. Per questo motivo, e per poter calcolare MAE e bias di conteggio (non forniti da alcuno strumento standard) con pieno controllo su matching e pooling, tutte le metriche sono state implementate da zero.

6.4 Ottimizzazione degli iperparametri operativi

Per ciascun gruppo di iperparametri, le predizioni vengono salvate una sola volta, con soglie molto permissive (confidence bassa, NMS quasi disattivata), evitando così di

dover rieseguire l'inferenza per ogni combinazione testata. Su queste predizioni si esplora una griglia congiunta dei parametri di interesse, calcolando per ciascuna combinazione F1 e MAE sul relativo set reale di riferimento. Tra tutte le combinazioni si selezionano le tre a F1 più alto, la metrica operativa primaria (paragrafo 6.2); tra queste tre, la combinazione finale viene scelta come quella con il MAE di conteggio più basso. Questo criterio a due stadi riflette l'obiettivo applicativo discusso nel paragrafo 6.1: a parità di qualità complessiva della detection (F1 comparabile), si preferisce la combinazione che minimizza l'errore di conteggio, la grandezza più direttamente legata allo scopo per cui la pipeline è stata sviluppata.

6.4.1 Soglie di confidence e IoU-NMS dei singoli modelli

Questo protocollo viene applicato separatamente al modello full e al modello zoom, esplorando per ciascuno una griglia congiunta di soglie di confidence e di IoU per la NMS (paragrafo 2.1) e valutando le combinazioni sul rispettivo set reale di test: le 15 immagini reali a campo intero (paragrafo 5.5) per il modello full, i 72 crop reali di test (paragrafo 5.3) per il modello zoom. Le due ottimizzazioni sono indipendenti tra loro, poiché i due modelli operano su porzioni distinte dell'immagine e vengono combinati solo nella fase di fusione successiva.

6.4.2 Margine e soglia IoU-NMS di confine per la fusione

Una volta fissati i punti operativi dei due modelli, lo stesso protocollo viene applicato ai due iperparametri specifici della fusione delle predizioni (paragrafo 5.4): il margine di tolleranza che definisce, attorno al confine di ciascuna zona densa, la cornice di competizione tra i due modelli e la soglia IoU della NMS applicata alle detection che vi ricadono. Anche in questo caso si esplora una griglia congiunta dei due parametri, valutando le combinazioni sulle stesse 15 immagini reali usate per il modello full.

Capitolo 7

Risultati sperimentali e discussione

Questo capitolo presenta i risultati sperimentali ottenuti applicando il protocollo di valutazione descritto nel capitolo precedente, secondo cui le metriche sono calcolate in modo pooled sull'intero dataset, cercando di dare pari importanza alla correttezza del conteggio e alla precisione di localizzazione del singolo box. La trattazione procede dai due modelli valutati singolarmente, full e zoom, fino alla pipeline dual-model completa, di cui si discute il confronto con il modello full singolo e il comportamento in termini di precision, recall e bias di conteggio. Il capitolo si chiude con una discussione dei limiti del lavoro svolto e con un confronto con il lavoro precedente sullo stesso compito di detection dei nuclei.

7.1 Modello full

Sul validation e sul test set sintetico il modello full raggiunge prestazioni pressoché sature (mAP@50 $\approx$ 98,5%, mAP@50-95 $\approx$ 90,9% su entrambi gli split), a conferma della buona convergenza dell'addestramento.

La figura 7.1 riporta le curve prodotte da YOLO durante le 250 epoche di training: le tre componenti della loss (box, classificazione, l1), calcolate sia sul training sia sul validation set, decrescono nel complesso (le loss di training box e l1 mostrano una temporanea risalita tra le epoche 50 e 130 circa, poi riassorbita), mentre precision, recall, mAP@50 e mAP@50-95 crescono rapidamente nelle prime epoche per poi stabilizzarsi su un plateau, senza segnali di overfitting.

Valutato sulle 15 immagini reali annotate, applicando il protocollo di selezione delle soglie operative descritto nel capitolo 6 (grid search congiunta su soglia di confidence e IoU di NMS, con selezione tra le tre combinazioni a F1 più alto in base al MAE di conteggio), la

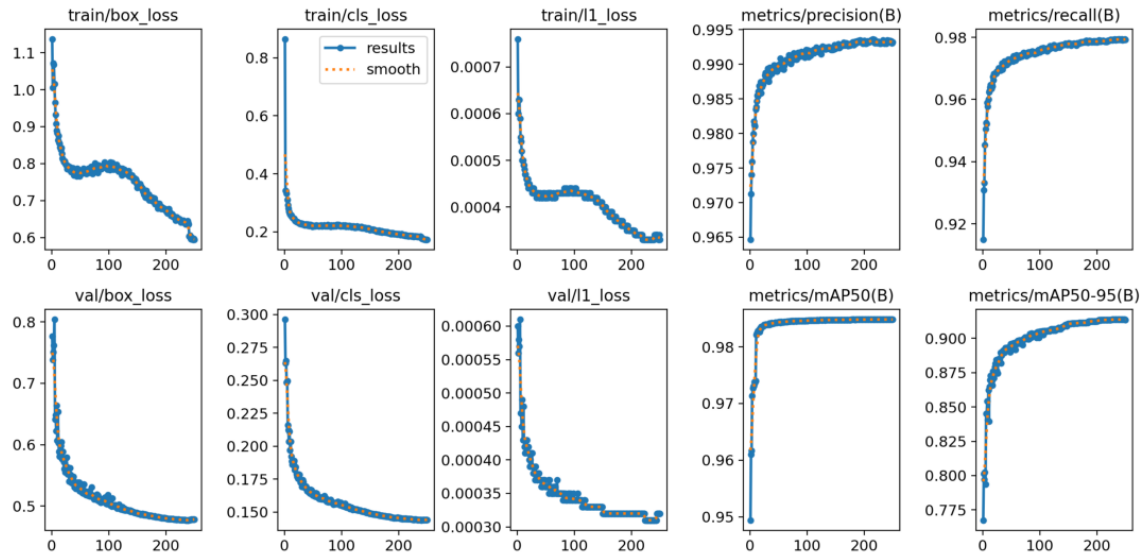


Figura 7.1: Curve di training del modello full (YOLO26l, 250 epoche): box loss, classification loss e l1 loss su training e validation set, e metriche di precision, recall, mAP@50 e mAP@50-95 calcolate da YOLO sul validation set sintetico a ogni epoca.

combinazione ottimale per il modello full risulta conf $= 0{,}6$, IoU-NMS $= 0{,}3$. Le metriche pooled a questo punto operativo sono riportate in tabella 7.1.

Tabella 7.1: Metriche del modello full sul set reale (15 immagini, 11 472 nuclei annotati), al punto operativo ottimale (conf $= 0{,}6$, IoU-NMS $= 0{,}3$).

Metrica	Valore
Precision	89,1%
Recall	78,8%
F1	83,7%
mAP@50	77,7%
MAE conteggio	102,07 nuclei/immagine
Bias conteggio	$-88{,}47$ nuclei/immagine

Il divario tra precision e recall indica un comportamento lievemente conservativo del modello, che tende a perdere nuclei realmente presenti più che a generare falsi positivi in eccesso. Questa lettura è confermata dal bias di conteggio: il valore negativo indica una sottostima sistematica, pari in media a circa l'11,6% del numero medio di nuclei annotati per immagine (≈ 765). Il fatto che il MAE sia relativamente vicino in valore assoluto al bias

suggerisce inoltre che l'errore di conteggio non sia distribuito casualmente tra le immagini, ma sia in gran parte sistematico e concorde in direzione, presumibilmente più marcato nelle regioni a densità elevata, dove nuclei adiacenti o sovrapposti risultano più difficili da separare correttamente. Questo limite motiva l'introduzione del modello zoom, discusso nel paragrafo seguente.

7.2 Modello zoom

La figura 7.2 mostra le curve della fase di pre-training: le tre componenti della loss decrescono regolarmente, mentre precision, recall e mAP crescono fino a stabilizzarsi su un plateau; l'addestramento si interrompe per early stopping prima di raggiungere le 200 epoche previste.

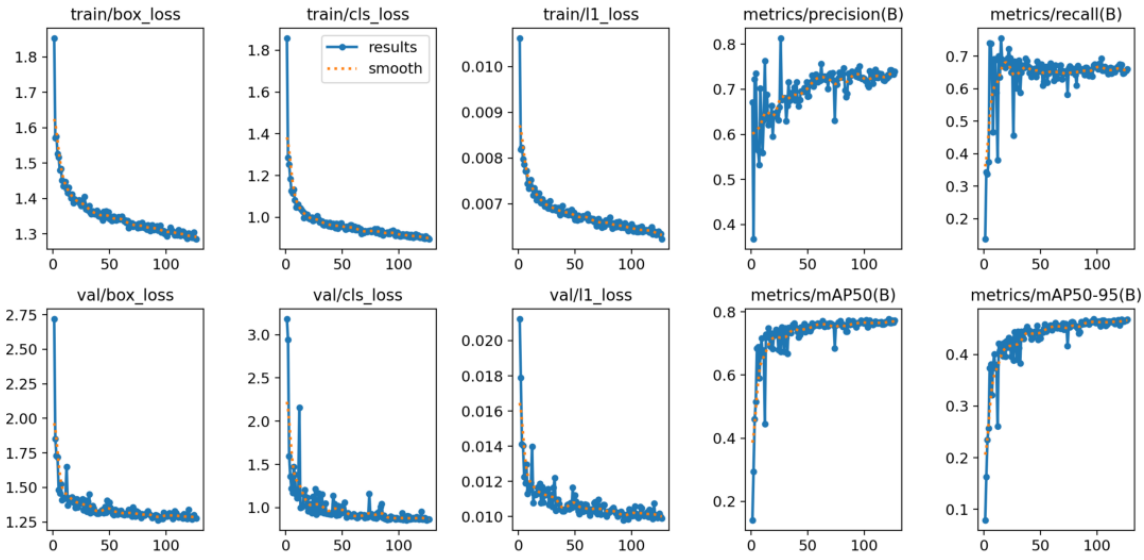


Figura 7.2: Curve della fase di pre-training del modello zoom (YOLO26l sul dataset sintetico di crop): box loss, classification loss e l1 loss su training e validation set, e metriche di precision, recall, mAP@50 e mAP@50-95 calcolate da YOLO sul validation set sintetico ad ogni epoca.

La figura 7.3 mostra invece le curve della fase di fine-tuning sul dataset reale: le loss, già basse grazie al trasferimento dai pesi del pre-training, calano ulteriormente, mentre precision, recall e mAP continuano a migliorare fino a un nuovo plateau più alto, senza segnali di overfitting nelle 80 epoche di training.

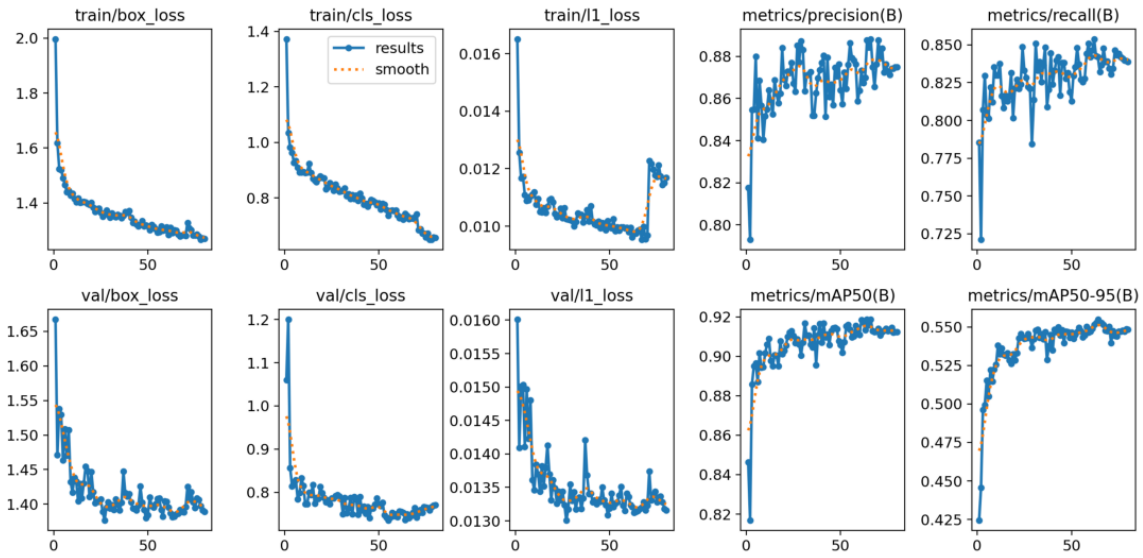


Figura 7.3: Curve della fase di fine-tuning del modello zoom (YOLO26l sul dataset reale di crop, a partire dai pesi del pre-training): box loss, classification loss e l1 loss su training e validation set, e metriche di precision, recall, mAP@50 e mAP@50-95 calcolate da YOLO sul validation set reale ad ogni epoca.

Applicando il protocollo di selezione delle soglie operative descritto nel capitolo precedente sulle 72 immagini (crop) del set di test reale, la combinazione ottimale per il modello zoom risulta conf $= 0{,}15$, IoU-NMS $= 0{,}4$. Le metriche pooled ottenute in corrispondenza di questa combinazione di soglie sono riportate in tabella 7.2.

Anche per il modello zoom il divario tra precision e recall indica un comportamento conservativo, qui ancora più marcato che nel modello full (17,4 punti percentuali di distanza, contro i 10,3 punti del modello full): la recall più bassa segnala una quota maggiore di nuclei mancati. Il bias di conteggio negativo conferma una sottostima sistematica, per quanto contenuta in valore assoluto vista la dimensione ridotta dei crop analizzati. Anche in questo caso il MAE risulta vicino in valore assoluto al bias, a indicare un errore di conteggio prevalentemente sistematico più che casuale.

7.3 Pipeline dual-model

La pipeline dual-model applica il modello full sull'intera immagine e il modello zoom sulle zone ad alta densità di nuclei individuate dal `BrightAreaExtractor` (paragrafo 3.3), secondo l'architettura descritta nel capitolo 5. Le detection dei due modelli vengono

Tabella 7.2: Metriche del modello zoom sul set reale (72 immagini/crop di test), al punto operativo ottimale (conf $= 0{,}15$, IoU-NMS $= 0{,}4$).

Metrica	Valore
Precision	89,8%
Recall	72,4%
F1	80,2%
mAP@50	70,8%
MAE conteggio	3,57 nuclei/immagine
Bias conteggio	$-3,10$ nuclei/immagine

infine combinate secondo la procedura di fusione descritta nel paragrafo 5.4: quelle del full classificate come *outside_far* e quelle dello zoom classificate come *inside_far* vengono mantenute direttamente (paragrafo 5.4.2), mentre quelle di entrambi i modelli classificate come *border* vengono filtrate con la NMS locale descritta nel paragrafo 5.4.3.

Full e zoom operano ai rispettivi punti operativi già individuati (conf $= 0{,}6$, IoU-NMS $= 0{,}3$ per il full; conf $= 0{,}15$, IoU-NMS $= 0{,}4$ per lo zoom). I due soli iperparametri specifici della fusione, margine di confine e soglia IoU della NMS di confine, sono stati selezionati con lo stesso protocollo (grid search, top-3 combinazioni per F1 con tie-break sul MAE di conteggio) sulle stesse 15 immagini reali usate per il modello full, ottenendo margine $= 50$ px, IoU-NMS di confine $= 0{,}25$.

Le metriche pooled ottenute a questo punto, sulle stesse 15 immagini reali, sono riportate in tabella 7.3.

All'interno di questo risultato, la precision resta comunque elevata (88,8%), mentre è soprattutto il recall (80,6%) a beneficiare del contributo del modello zoom nelle zone dense, coerentemente con il ruolo assegnatogli. Il lieve calo di precision rispetto al full singolo (89,1%) è compatibile con l'introduzione di qualche falso positivo nella fascia di confine, dove le detection dei due modelli competono.

7.3.1 Confronto con il modello full singolo

La tabella 7.4 confronta i risultati della pipeline dual-model con quelli del modello full singolo, sulle stesse 15 immagini reali.

Tabella 7.3: Metriche della pipeline dual-model sul set reale (15 immagini, stesso set del modello full), al punto operativo ottimale (margine $= 50$ px, IoU-NMS di confine $= 0{,}25$).

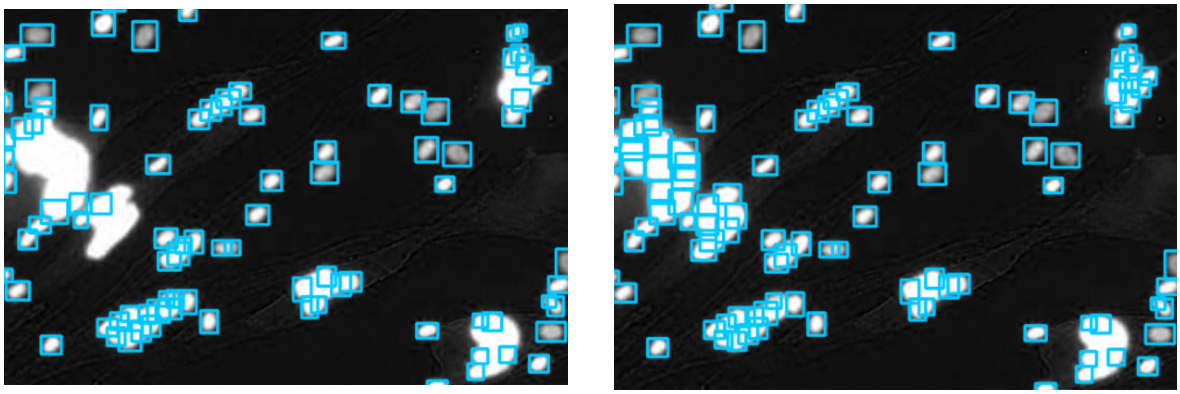
Metrica	Valore
Precision	88,8%
Recall	80,6%
F1	84,5%
mAP@50	79,5%
MAE conteggio	91,33 nuclei/immagine
Bias conteggio	$-71{,}07$ nuclei/immagine

Tabella 7.4: Confronto tra il modello full singolo e la pipeline dual-model, sulle 15 immagini reali.

Metrica	Full singolo	Pipeline dual-model
Precision	89,1%	88,8%
Recall	78,8%	80,6%
F1	83,7%	84,5%
mAP@50	77,7%	79,5%
MAE conteggio	102,07	91,33
Bias conteggio	$-88{,}47$	$-71{,}07$

Rispetto al full singolo, la pipeline dual-model migliora F1 (+0,8 punti percentuali), mAP@50 (+1,8 punti) e soprattutto recall (+1,8 punti), a fronte di un calo marginale di precision ($-0,3$ punti). Il guadagno di recall è coerente con l'obiettivo della pipeline: recuperare, tramite il modello zoom, nuclei nelle zone dense che il full da solo tende a perdere. Anche l'errore di conteggio migliora: il MAE scende da 102,07 a 91,33 nuclei per immagine ($-10,5\%$) e il bias, pur restando negativo, si riduce in valore assoluto da 88,47 a 71,07 ($-19,7\%$), a indicare una sottostima sistematica meno marcata.

La figura 7.4 mostra il dettaglio di una zona densa di una immagine reale di test, una delle aree in cui entrambi i modelli faticano di più: il miglioramento nell'individuare i nuclei da full singolo a pipeline dual-model è evidente anche in seguito ad un'analisi visiva.



Modello singolo full **Pipeline dual-model**

Figura 7.4: Dettaglio di una zona densa della stessa immagine reale di test: il full singolo (sinistra) copre solo in parte il cluster di nuclei sovrapposti, mentre la pipeline dual-model (destra) ne rileva un numero maggiore.

7.4 Limiti del lavoro

Pur avendo mostrato un miglioramento rispetto al modello full singolo, la pipeline sviluppata presenta alcuni limiti, discussi nei paragrafi seguenti.

7.4.1 Dimensione del dataset reale

Il dataset reale annotato manualmente, composto da 15 immagini a campo intero e 715 crop di zone dense, è di dimensioni contenute. Questa scarsità di dati ha guidato diverse scelte metodologiche descritte nei capitoli precedenti, dal ricorso alla generazione sintetica

al fine-tuning con backbone parzialmente congelato del modello zoom. Le stesse 15 immagini reali vengono inoltre utilizzate sia per l'ottimizzazione degli iperparametri operativi (soglie, margine di confine) sia per la valutazione finale della pipeline: le metriche riportate in questo capitolo sono quindi probabilmente lievemente ottimistiche rispetto a quanto la pipeline otterrebbe su immagini non coinvolte nemmeno nella fase di ottimizzazione.

7.4.2 Incertezza delle annotazioni negli ammassi densi

Come anticipato nel paragrafo 3.2, nelle regioni a densità cellulare più elevata la separazione tra nuclei adiacenti può risultare ambigua anche per un annotatore umano, che deve inferire la presenza di più nuclei distinti da sottili discontinuità di forma o di intensità del segnale fluorescente, non potendo contare su un confine netto e univoco. La figura 7.5 mostra un esempio di questo tipo di ammasso, a sinistra, e la relativa annotazione manuale, a destra: un altro annotatore, di fronte alla stessa immagine, avrebbe potuto ragionevolmente tracciare un numero di bounding box leggermente diverso, senza che nessuna delle due letture possa ritenersi sbagliata.

Questa ambiguità ha una conseguenza diretta sulla valutazione: il ground truth stesso, nelle zone più dense, non è un riferimento del tutto certo, ma è sempre influenzato da una interpretazione soggettiva.

7.4.3 Calibrazione empirica del BrightAreaExtractor

I due parametri che regolano l'estrazione delle zone dense, la soglia di luminosità e l'area minima (paragrafo 3.3), sono stati fissati empiricamente tramite verifica visiva su un campione di immagini, senza una procedura di ottimizzazione sistematica analoga a quella adottata per le soglie operative della pipeline (paragrafo 6.4). Questi valori potrebbero non generalizzare altrettanto bene a immagini acquisite in condizioni diverse da quelle del dataset a disposizione, ad esempio con un'esposizione o un'intensità di colorazione differenti, per le quali la stessa soglia di luminosità potrebbe includere o escludere regioni dense in modo meno accurato.

7.4.4 Generalizzazione limitata al protocollo di acquisizione

Sia le immagini reali sia il generatore sintetico si basano su un unico protocollo di acquisizione, lo stesso microscopio a fluorescenza e la stessa colorazione DAPI. Resta

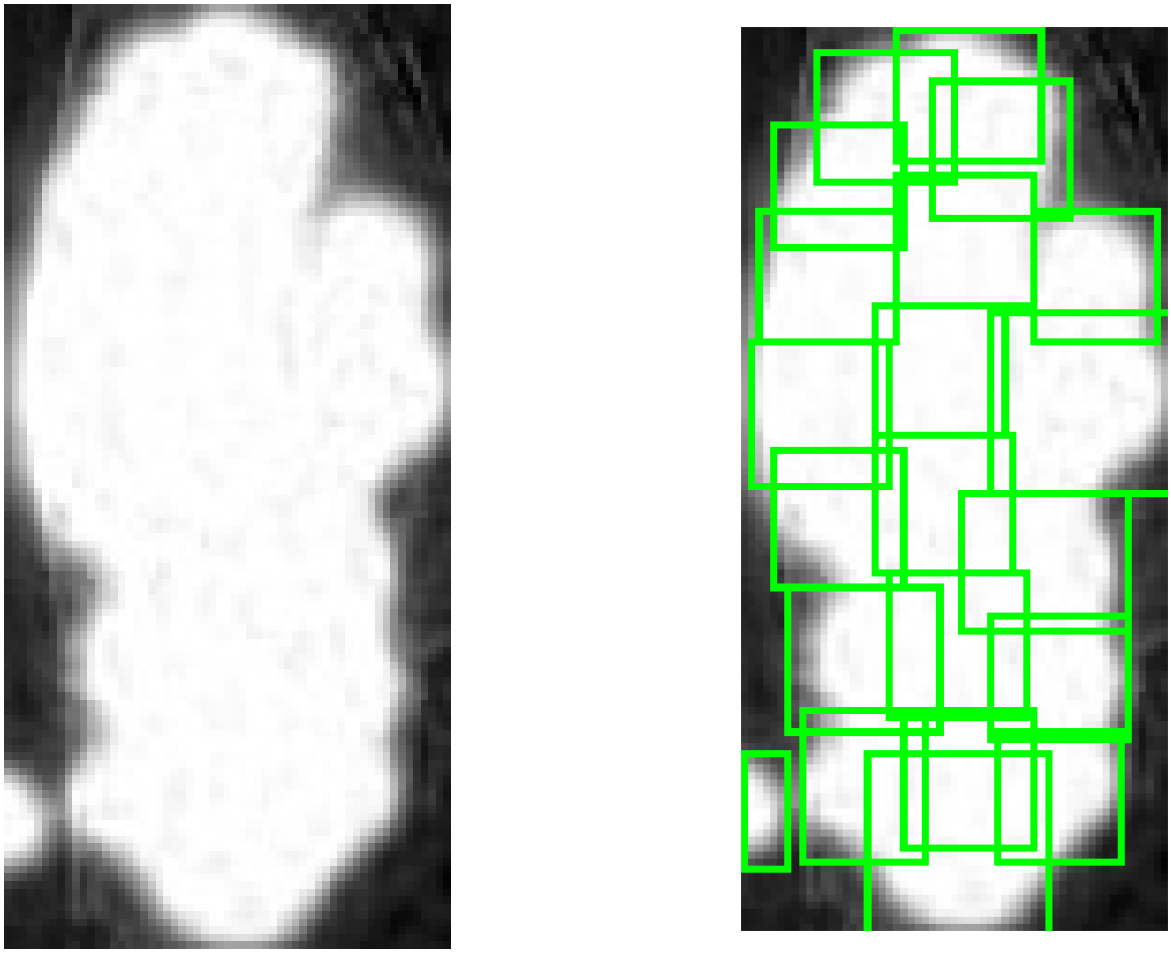


Immagine originale **Con annotazione manuale**

Figura 7.5: Esempio di ammasso denso di nuclei in cui il confine tra nuclei adiacenti è visivamente ambiguo (sinistra) e la relativa annotazione manuale (destra): la scelta di quanti nuclei distinti individuare, e dove tracciarne il confine, richiede un giudizio soggettivo.

dunque da valutare se le prestazioni ottenute si mantengano su immagini acquisite con strumentazione, colorazione o impostazioni diverse, in quale misura eventualmente degradino e a causa di quali fattori specifici, ad esempio differenze di rumore, di esposizione o di intensità della colorazione rispetto al protocollo di acquisizione utilizzato in questo lavoro.

7.5 Confronto con lavoro precedente

Come discusso nel paragrafo 6.1, un confronto diretto con benchmark generici di object detection ha un valore limitato in questo dominio, data la specificità del compito. L'unico confronto realmente comparabile è con il lavoro precedente [9] svolto dalla dottoressa Zhu Yiyi, che ha affrontato lo stesso compito di detection dei nuclei con un modello YOLOv5.

Per garantire un confronto equo, il modello precedente è stato valutato sulle stesse 15 immagini reali usate in questa tesi, applicando lo stesso protocollo di selezione delle soglie operative descritto nel capitolo precedente, anziché affidarsi a metriche eventualmente riportate nel lavoro originale, calcolate con un criterio diverso e quindi non direttamente confrontabili. La tabella 7.5 riporta il risultato di questo confronto.

Tabella 7.5: Confronto tra il modello precedente (YOLOv5), il modello full singolo e la pipeline dual-model, sulle stesse 15 immagini reali e con lo stesso protocollo di selezione delle soglie operative.

Metrica	Zhu (YOLOv5)	Full singolo	Pipeline dual-model
Precision	82,9%	89,1%	88,8%
Recall	56,2%	78,8%	80,6%
F1	67,0%	83,7%	84,5%
mAP@50	52,9%	77,7%	79,5%
MAE conteggio	246,00	102,07	91,33
Bias conteggio	$-246,00$	$-88,47$	$-71,07$

Questo modello precedente ottiene un F1 del 67,0%, sensibilmente più basso sia del modello full singolo (83,7%) sia della pipeline dual-model (84,5%) sviluppati in questa tesi. Il divario è dominato dal recall (56,2% contro 78,8% e 80,6%): il suo modello perde una quota consistente di nuclei, coerentemente con un MAE di conteggio molto più alto (246,00

nuclei per immagine) e un bias praticamente coincidente con il MAE in valore assoluto ($-246,00$), segno che tutte le 15 immagini vengono sottostimate, senza eccezioni.

Un divario di questa entità è verosimilmente attribuibile a un insieme di scelte metodologiche introdotte in questa tesi, più che a un singolo fattore isolato:

- la disponibilità di un dataset reale annotato, con 15 immagini a campo intero e oltre 700 crop di zone dense, usato per calibrare il generatore sintetico e per l'ottimizzazione degli iperparametri operativi;
- un generatore di immagini sintetiche calibrato sulle statistiche estratte dai dati reali annotati, esteso con cluster lineari ed ellittici per riprodurre l'organizzazione spaziale osservata nei dati reali;
- l'architettura dual-model, che affianca al modello full-image un modello specializzato sulle zone dense;
- il `BrightAreaExtractor`, che individua automaticamente tali zone a partire dalla sola immagine;
- il fine-tuning in due fasi del modello zoom, che ne adatta i pesi pre-addestrati sul sintetico alle immagini reali nonostante la scarsità di dati disponibili.

Capitolo 8

Conclusioni e sviluppi futuri

8.1 Sintesi del lavoro e dei risultati

L'obiettivo di questa tesi era sviluppare una pipeline automatizzata per il conteggio dei nuclei cellulari in immagini di microscopia a fluorescenza, con particolare attenzione alle regioni in cui i nuclei sono densamente aggregati. A tale scopo è stata costruita la pipeline dual-model (capitolo 5): un primo modello YOLO di object detection[1] opera sull'intera immagine, mentre un secondo modello è dedicato alle zone dense, dove i nuclei sono più ammassati e difficili da separare. Queste zone vengono individuate automaticamente da un algoritmo sviluppato in questo lavoro, il `BrightAreaExtractor`, che sfrutta il fatto che gli ammassi di nuclei appaiono nell'immagine come regioni più luminose: l'algoritmo seleziona le aree che superano una soglia di luminosità e un'area minima, e le ritaglia dall'immagine originale. Il secondo modello analizza poi ciascun ritaglio separatamente, come se lo osservasse con un ingrandimento maggiore, così che i singoli nuclei risultino più grandi e più facili da distinguere. Le predizioni dei due modelli vengono infine combinate da una procedura di fusione che applica la Non-Maximum Suppression (NMS, la tecnica che elimina le predizioni duplicate o sovrapposte mantenendo solo quella con la confidenza più alta) soltanto alla cornice di confine tra le zone, dove le predizioni dei due modelli possono sovrapporsi.

Per ovviare alla scarsità di dati reali annotati, dovuta al fatto che etichettare manualmente centinaia di nuclei per immagine richiede molto tempo, sono stati sviluppati tre

[1] L'object detection (o rilevamento di oggetti) è una tecnica di computer vision che permette di individuare la presenza e la posizione di oggetti specifici all'interno di un'immagine o di un video, comunemente utilizzata ad esempio dagli smartphone per individuare i volti nelle fotografie.

generatori di immagini sintetiche (full-image, zoom e casi difficili), calibrati sulle statistiche descrittive dei dati reali in modo da riprodurne densità, dimensione e luminosità dei nuclei (capitolo 4): il modello full è addestrato esclusivamente su dati sintetici, mentre il modello zoom è pre-addestrato sul sintetico e rifinito su ritagli reali, con esempi sintetici dedicati agli ammassi più densi.

Poiché le metriche COCO (Common Objects in Context), tradizionalmente usate nell'object detection, sono poco adatte a un compito in cui conta più il conteggio corretto che la precisione di localizzazione (paragrafo 6.1), è stato definito un protocollo di valutazione basato su F1, mAP@50 e su due metriche di conteggio, adattate a partire dal mean absolute error (MAE) e dal bias: la prima misura lo scarto medio in valore assoluto tra nuclei contati e nuclei annotati, la seconda ne indica la direzione (sovrastima o sottostima). Tutti i modelli di object detection sviluppati sono valutati alle soglie di confidence e di NMS individuate tramite una ricerca congiunta, che prova tutte le combinazioni dei due parametri e per ciascuna calcola F1 e MAE di conteggio. La scelta avviene in due passaggi: si selezionano le tre combinazioni con l'F1 più alto e, tra queste, si adotta quella con il MAE più basso, così che, a parità di qualità complessiva delle detection, prevalga la combinazione che sbaglia meno il conteggio dei nuclei (capitolo 6). Sulle 15 immagini reali la pipeline dual-model raggiunge un F1 dell'84,5% e un MAE di conteggio di 91,33 nuclei per immagine. Rispetto al solo modello full migliora F1, recall, mAP@50 e le metriche di conteggio, con un calo marginale di precision (paragrafo 7.3.1). Rispetto al lavoro precedente, valutato sulle stesse immagini e con lo stesso protocollo, l'F1 sale dal 67,0% all'84,5% e il MAE scende da 246,00 a 91,33 nuclei per immagine (paragrafo 7.5).

8.2 Implicazioni applicative e limiti residui

Sulle immagini analizzate resta comunque una sottostima sistematica: il bias medio di $-71{,}07$ nuclei per immagine corrisponde a circa il 9% del numero medio di nuclei annotati (764,8) e, in valore assoluto, è pari a quasi l'80% del MAE, segno di un errore concorde in direzione più che casuale. Come discusso nel paragrafo 7.4.2, questo errore residuo si concentra nelle zone dense, individuate dal `BrightAreaExtractor`, dove anche per una persona è difficile distinguere i singoli nuclei.

Questo limite può essere ridotto affiancando alla pipeline un processo di ispezione svolto da una persona, il cui carico di lavoro resta però molto inferiore a quello di un'annota-

zione manuale completa: l'operatore dovrebbe infatti limitarsi a verificare le sole zone dense segnalate dal `BrightAreaExtractor`, dove la maggior parte dei nuclei risulta già correttamente individuata dalla pipeline, per cui il suo compito si riduce perlopiù ad aggiungerne alcuni mancanti piuttosto che a un'annotazione da zero. Al di fuori delle zone dense, dove il confine tra nuclei è netto anche per un annotatore umano (paragrafo 7.4.2), il conteggio automatico può sostituire il lavoro dell'operatore senza bisogno di alcuna verifica, con un risparmio di tempo sostanziale rispetto all'etichettatura manuale completa.

8.3 Considerazioni conclusive

Il risultato principale di questo lavoro è aver mostrato che il conteggio automatico dei nuclei cellulari è praticabile anche quando i dati reali annotati sono molto scarsi. Due scelte si sono rivelate decisive. La prima è stata scomporre il problema in base alla densità: anziché affidare a un unico modello sia le regioni in cui i nuclei sono ben separati sia quelle in cui si ammassano, la pipeline creata assegna le aree dense di nuclei a un modello specializzato, che le analizza a un ingrandimento maggiore. La seconda è stata sostituire gran parte dell'annotazione manuale con immagini sintetiche, generate in modo da riprodurre le caratteristiche dei dati reali.

Sul piano metodologico, il lavoro fornisce due indicazioni. In primo luogo, dati sintetici calibrati con cura sulle statistiche dei dati reali possono bastare ad addestrare un modello di detection utilizzabile su immagini reali. In secondo luogo, per un compito di conteggio non basta verificare quanti nuclei vengono individuati correttamente: occorre anche misurare di quanto il numero di nuclei contati si discosta da quello reale, e in quale direzione. È stato il bias di conteggio a mostrare che la pipeline tende a sottostimare il numero di nuclei nelle zone dense.

Sul piano applicativo, la pipeline non elimina il ruolo dell'esperto, ma ne cambia la natura: da un conteggio completo, lungo e soggetto a variabilità tra operatori, a una revisione mirata delle sole zone dense. In questo senso la pipeline va intesa come uno strumento intermedio, il cui valore si misurerà pienamente quando i conteggi verranno impiegati per calcolare gli indici biologici che, nello studio della FSHD, descrivono la capacità delle cellule muscolari di differenziarsi e fondersi. Verso questo obiettivo sono orientati gli sviluppi descritti nel paragrafo successivo.

8.4 Sviluppi futuri

Accanto ai risultati raggiunti, restano alcuni margini di miglioramento, che indicano altrettante direzioni di lavoro: ampliare e validare meglio il dataset reale, ridurre la sottostima nelle zone dense, verificare la tenuta della pipeline su altri protocolli di acquisizione e, infine, collegare il conteggio dei nuclei agli indici biologici che ne motivano l'uso.

8.4.1 Dataset reale più ampio e variabilità nell'annotazione

Un possibile sviluppo futuro consiste nell'ampliare il dataset reale annotato: le 15 immagini a campo intero attualmente disponibili sono poche per raccogliere appieno la variabilità da immagine a immagine. Sarebbe utile anche far annotare le stesse immagini da più operatori, in particolare negli ammassi densi (paragrafo 7.4.2), per evidenziare e quantificare la variabilità di annotazione.

8.4.2 Zone dense e sottostima residua

Una seconda direzione riguarda le zone dense, dove si concentra verosimilmente la sottostima residua. I due parametri del `BrightAreaExtractor` (soglia di luminosità e area minima) sono oggi fissati tramite verifica visiva (paragrafo 7.4.3); potrebbero essere ottimizzati in modo sistematico con la stessa logica di grid search già usata per le soglie operative della pipeline. Per gli ammassi a densità estrema, in cui la detection di singole bounding box è intrinsecamente ambigua, si potrebbe invece sviluppare un programma dedicato che individui queste zone, ne calcoli l'area occupata e stimi da questa il numero di nuclei presenti, anziché tentare di localizzare ogni singolo nucleo.

8.4.3 Generalizzazione ad altri protocolli di acquisizione

Occorre poi verificare le prestazioni su immagini acquisite con strumentazione, colorazione o impostazioni diverse (paragrafo 7.4.4). In caso di degrado, il generatore sintetico potrebbe essere esteso con variazioni di rumore, esposizione e intensità della colorazione, oppure il modello potrebbe essere adattato con un fine-tuning su un piccolo campione del nuovo dominio, come già fatto per il modello zoom.

8.4.4 Dal conteggio agli indici biologici

Infine, resta da collegare la pipeline all'obiettivo biologico delineato nel capitolo introduttivo: il calcolo degli indici che misurano la capacità delle cellule muscolari di differenziarsi e fondersi in strutture multinucleate, i miotubi. Il passo successivo è integrare i conteggi dei nuclei con le informazioni contenute nel canale delle immagini dedicato ai miotubi, non utilizzato in questo lavoro, e valutare la pipeline sul compito finale, ossia verificare se gli indici calcolati automaticamente consentono di distinguere in modo affidabile l'effetto di trattamenti sperimentali, confrontandoli con quelli ottenuti manualmente.

Bibliografia

[1] Ultralytics, "Ultralytics benchmark visualization." https://docs.ultralytics.com/modes/benchmark, 2026. Consultato il 24 agosto 2026.

[2] E. Mocciaro, V. Runfola, P. Ghezzi, M. Pannese, and D. Gabellini, "DUX4 role in normal physiology and in FSHD muscular dystrophy," *Cells*, vol. 10, no. 12, p. 3322, 2021.

[3] E. Mocciaro, R. Giambruno, S. Micheloni, F. M. Cernilogar, A. Andolfo, C. Consonni, M. Pannese, G. Ferri, V. Runfola, G. Schotta, and D. Gabellini, "WDR5 is required for DUX4 expression and its pathological effects in FSHD muscular dystrophy," *Nucleic Acids Research*, vol. 51, no. 10, pp. 5144–5161, 2023.

[4] T.-Y. Lin, M. Maire, S. Belongie, L. Bourdev, R. Girshick, J. Hays, P. Perona, D. Ramanan, C. L. Zitnick, and P. Dollár, "Microsoft COCO: Common objects in context," in *Proceedings of the European Conference on Computer Vision (ECCV)*, pp. 740–755, 2014.

[5] M. Everingham, L. Van Gool, C. Williams, J. Winn, and A. Zisserman, "The PASCAL visual object classes (VOC) challenge," *International Journal of Computer Vision*, vol. 88, no. 2, pp. 303–338, 2010.

[6] A. Zhang, Z. C. Lipton, M. Li, and A. J. Smola, *Dive into Deep Learning*. Cambridge University Press, 2023.

[7] M. Nikouei, B. Baroutian, S. Nabavi, F. Taraghi, A. Aghaei, A. Sajedi, and M. E. Moghaddam, "Small object detection: A comprehensive survey on challenges, techniques and real-world applications," *Intelligent Systems with Applications*, vol. 27, p. 200561, 2025.

[8] H. Yu, J. Liu, and M. Lin, "A comprehensive literature review on YOLO-based small object detection: Methods, challenges, and future trends," *Computers, Materials & Continua*, vol. 87, no. 1, 2026.

[9] Y. Zhu, "Segmentazione di miotubi muscolari e riconoscimento di nuclei in immagini da microscopio," tesi di laurea magistrale in Biostatistica, Università degli Studi di Milano-Bicocca, 2024. Relatore: Mirko Cesarini; Correlatore: Emanuele Mocciaro.

[10] P. F. Felzenszwalb, R. B. Girshick, D. McAllester, and D. Ramanan, "Object detection with discriminatively trained part-based models," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 32, no. 9, pp. 1627–1645, 2010.

[11] K. O'Shea and R. Nash, "An introduction to convolutional neural networks." arXiv:1511.08458, 2015.

[12] R. Girshick, J. Donahue, T. Darrell, and J. Malik, "Region-based convolutional networks for accurate object detection and segmentation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 38, no. 1, pp. 142–158, 2016.

[13] J. R. R. Uijlings, K. E. A. van de Sande, T. Gevers, and A. W. M. Smeulders, "Selective search for object recognition," *International Journal of Computer Vision*, vol. 104, no. 2, pp. 154–171, 2013.

[14] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You only look once: Unified, real-time object detection," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 779–788, 2016.

[15] J. Redmon and A. Farhadi, "YOLO9000: Better, faster, stronger," in *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 6517–6525, 2017.

[16] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, pp. 448–456, 2015.

[17] J. Redmon and A. Farhadi, "YOLOv3: An incremental improvement." arXiv:1804.02767, 2018.

[18] J. Terven, D.-M. Córdova-Esparza, and J.-A. Romero-González, "A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS," *Machine Learning and Knowledge Extraction*, vol. 5, no. 4, pp. 1680–1716, 2023.

[19] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, "YOLOv4: Optimal speed and accuracy of object detection." arXiv:2004.10934, 2020.

[20] G. Jocher, "YOLOv5 by Ultralytics." https://github.com/ultralytics/yolov5, 2020. Version 7.0, DOI: 10.5281/zenodo.3908559.

[21] C. Li, L. Li, H. Jiang, K. Weng, Y. Geng, L. Li, Z. Ke, Q. Li, M. Cheng, W. Nie, Y. Li, B. Zhang, Y. Liang, L. Zhou, X. Xu, X. Chu, X. Wei, and X. Wei, "YOLOv6: A single-stage object detection framework for industrial applications." arXiv:2209.02976, 2022.

[22] C.-Y. Wang, A. Bochkovskiy, and H.-Y. M. Liao, "YOLOv7: Trainable bag-of-freebies sets new state-of-the-art for real-time object detectors," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 7464–7475, 2023.

[23] M. Yaseen, "What is YOLOv8: An in-depth exploration of the internal features of the next-generation object detector." arXiv:2408.15857, 2024.

[24] C.-Y. Wang, I.-H. Yeh, and H.-Y. M. Liao, "YOLOv9: Learning what you want to learn using programmable gradient information," in *Proceedings of the European Conference on Computer Vision (ECCV)*, 2024.

[25] A. Wang, H. Chen, L. Liu, K. Chen, Z. Lin, J. Han, and G. Ding, "YOLOv10: Real-time end-to-end object detection," in *Advances in Neural Information Processing Systems*, vol. 37, Curran Associates, Inc., 2024.

[26] R. Khanam and M. Hussain, "YOLOv11: An overview of the key architectural enhancements." arXiv:2410.17725, 2024.

[27] R. Sapkota, R. H. Cheppally, A. Sharda, and M. Karkee, "YOLO26: Key architectural enhancements and performance benchmarking for real-time object detection." arXiv:2509.25164, 2026.

[28] L. Wu, A. Chen, P. Salama, S. Winfree, K. W. Dunn, and E. J. Delp, "NISNet3D: three-dimensional nuclear synthesis and instance segmentation for fluorescence microscopy images," *Scientific Reports*, vol. 13, no. 1, p. 9533, 2023.

[29] P. Iacono and N. Khan, "Structure preserving Cycle-GAN for unsupervised medical image domain adaptation," in *2024 46th Annual International Conference of the IEEE Engineering in Medicine and Biology Society (EMBC)*, pp. 1–5, 2024.

[30] S. Suzuki and K. Abe, "Topological structural analysis of digitized binary images by border following," *Computer Vision, Graphics, and Image Processing*, vol. 30, no. 1, pp. 32–46, 1985.